

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



BÁO CÁO ĐỒ ÁN I
HỌC PHẦN ĐỒ ÁN NGHIÊN CỨU

DỰ BÁO RỦI RO VỐ NỢ
TÍN DỤNG BẰNG MACHINE
LEARNING

Giảng viên hướng dẫn: TS. Nguyễn Cảnh Nam

Sinh viên thực hiện: Đoàn Danh Long

Mã số sinh viên: 20237354

Học kỳ: 2025.2

Hà Nội, tháng 6 năm 2026

Lời mở đầu

Hoạt động tín dụng là xương sống của hệ thống ngân hàng, nhưng đi kèm với nó là rủi ro vỡ nợ — khi người vay mất khả năng trả nợ. Việc đánh giá rủi ro chính xác trước khi cấp tín dụng quyết định trực tiếp đến chất lượng tài sản và sự an toàn của tổ chức cho vay. Quy trình thẩm định thủ công truyền thống vừa tốn kém, vừa khó mở rộng quy mô, vừa mang tính chủ quan; trong khi các mô hình chấm điểm tuyến tính cổ điển (như FICO) bỏ qua phần lớn các tương tác phi tuyến giữa các yếu tố tài chính.

Học máy (Machine Learning) cung cấp một hướng tiếp cận khác: học quy luật rủi ro trực tiếp từ dữ liệu lịch sử của hàng trăm nghìn hồ sơ vay, nắm bắt các quan hệ phi tuyến phức tạp mà mô hình tuyến tính không biểu diễn được. Tuy nhiên, một mô hình tốt trong bài toán tín dụng không chỉ cần *chính xác* mà còn phải *giải thích được* (do ràng buộc pháp lý khi từ chối khách hàng) và *phù hợp với chi phí kinh doanh* (vì bỏ sót một người sẽ vỡ nợ tốn kém hơn nhiều so với từ chối nhầm một người tốt).

Báo cáo này trình bày một cách hệ thống toàn bộ quy trình xây dựng một hệ thống dự báo rủi ro vỡ nợ trên bộ dữ liệu *Give Me Some Credit* (Kaggle): từ cơ sở lý thuyết của các mô hình phân loại, khám phá và tiền xử lý dữ liệu, thiết kế đặc trưng, huấn luyện và so sánh bốn mô hình (Hồi quy Logistic, Cây quyết định, Rừng ngẫu nhiên, XGBoost), đến diễn giải mô hình bằng giá trị SHAP, tối ưu ngưỡng quyết định theo chi phí, và đóng gói thành một ứng dụng web hoàn chỉnh. Toàn bộ nội dung được sắp xếp từ cơ sở lý thuyết đến thực nghiệm và ứng dụng, nhằm tạo thành một bản tổng hợp nhất quán và dễ theo dõi.

Lời cảm ơn

Em xin gửi lời cảm ơn chân thành đến Giảng viên hướng dẫn — Thầy Nguyễn Cảnh Nam, Khoa Toán–Tin, Trường Đại học Bách Khoa Hà Nội — đã tận tình hướng dẫn, góp ý và định hướng trong suốt quá trình thực hiện đồ án.

Em cũng xin cảm ơn gia đình và bạn bè đã luôn động viên, tạo điều kiện thuận lợi để em có thể hoàn thành đồ án đúng tiến độ. Dù đã cố gắng hết sức, báo cáo chắc chắn còn nhiều thiếu sót. Em rất mong nhận được nhận xét và góp ý từ Thầy để tiếp tục cải thiện trong những nghiên cứu tiếp theo.

Hà Nội, tháng 6 năm 2026 — Đoàn Danh Long

Tóm tắt

Báo cáo trình bày nghiên cứu ứng dụng học máy vào bài toán dự báo rủi ro vỡ nợ tín dụng, sử dụng bộ dữ liệu *Give Me Some Credit* (Kaggle, 149.999 hồ sơ vay). Bốn mô hình được xây dựng và đánh giá: Hồi quy Logistic ($AUC = 0,8432$), Cây quyết định ($0,8579$), Rừng ngẫu nhiên ($0,8703$) và XGBoost ($0,8714$). XGBoost vượt mục tiêu ($AUC > 0,87$) nhờ thiết kế đặc trưng có chủ đích, trong đó hai đặc trưng tự thiết kế lọt vào top-3 theo giá trị SHAP. Ngưỡng quyết định được tối ưu theo F_2 tại $t = 0,625$, đạt Recall 66,9% và giảm chi phí ước tính khoảng 2,01 triệu USD so với ngưỡng tối ưu theo F_1 . Sản phẩm cuối là một ứng dụng Streamlit tương tác, hỗ trợ dự báo đơn lẻ kèm giải thích SHAP và đánh giá theo lô.

Từ khóa: dự báo vỡ nợ, XGBoost, SHAP, F_β -score, dữ liệu mất cân bằng.

Mục lục

Lời mở đầu	i
Lời cảm ơn	ii
Tóm tắt	iii
Bảng thuật ngữ viết tắt	vii
1 Giới thiệu	1
1.1 Tính cấp thiết	1
1.2 Mục tiêu (SMART)	1
1.3 Phạm vi	1
1.4 Đóng góp chính và quy trình tổng quan	2
2 Cơ sở lý thuyết	3
2.1 Bài toán phân loại nhị phân	3
2.2 Hồi quy Logistic	3
2.3 Cây quyết định (CART)	4
2.4 Bagging và Rừng ngẫu nhiên	4
2.5 Gradient Boosting và XGBoost	5
2.6 Độ đo đánh giá	6
2.7 Diễn giải mô hình bằng SHAP	6
2.8 Hiệu chỉnh xác suất và kiểm định thống kê	7
3 Dữ liệu và Tiền xử lý	8
3.1 Khám phá dữ liệu (EDA)	8
3.2 Xử lý giá trị thiếu	8
3.3 Chuẩn hóa	8
3.4 Thiết kế đặc trưng	11
3.5 Mất cân bằng lớp	11
4 Thực nghiệm và Đánh giá	13
4.1 Thiết kế thử nghiệm	13
4.2 So sánh mô hình	13
4.3 Diễn giải SHAP	13

4.4	Tối ưu ngưỡng theo F_2	13
4.5	Phân tích lỗi và hiệu chỉnh xác suất	17
5	Sản phẩm — Ứng dụng Streamlit	18
5.1	Kiến trúc hệ thống	18
5.2	Tính năng chính	18
5.3	Chạy thử hậu kiểm theo lô	18
5.4	Kết quả thử nộp Kaggle	20
6	Kết luận và Hướng phát triển	21
6.1	Kết luận	21
6.2	Hướng phát triển	21
	Tài liệu tham khảo	22
A	Siêu tham số XGBoost	23
B	Hình kỹ thuật bổ sung	24

Danh sách hình vẽ

1.1	Sơ đồ quy trình tổng quan của đề án.	2
3.1	Phân bố lớp mục tiêu — mất cân bằng $\approx 14:1$	8
3.2	Phân phối đơn biến của các đặc trưng gốc.	9
3.3	Ma trận tương quan giữa các đặc trưng.	10
3.4	Phân tích nhóm biến trễ hạn theo tỷ lệ vỡ nợ.	10
3.5	So sánh phân phối trước/sau khi điền khuyết bằng KNN.	11
3.6	Minh họa SMOTE sinh mẫu lớp thiểu số.	12
4.1	So sánh tổng hợp các chỉ số giữa bốn mô hình.	14
4.2	Đường ROC của bốn mô hình trên tập kiểm tra.	15
4.3	Tầm quan trọng đặc trưng theo giá trị SHAP.	16
4.4	Tối ưu ngưỡng vận hành theo F_2	16
4.5	Phân bố điểm rủi ro của hai lớp quanh ngưỡng quyết định.	17
4.6	Đường hiệu chỉnh xác suất trước và sau Platt scaling.	17
5.1	Kiến trúc lớp của ứng dụng Streamlit.	18
5.2	Ma trận nhầm lẫn (trái) và tác động chi phí (phải) trên demo theo lô.	19
5.3	Kết quả nộp thử trên Kaggle.	20
B.1	Thông tin tương hỗ giữa đặc trưng và nhãn.	24
B.2	Đồ thị phụ thuộc SHAP cho đặc trưng chính.	24
B.3	Đường cong học của XGBoost.	25
B.4	Tóm tắt kiểm định DeLong giữa các mô hình.	25

Bảng thuật ngữ viết tắt

Thuật ngữ	Giải nghĩa
AUC-ROC	Diện tích dưới đường cong ROC — đo khả năng xếp hạng. 0,5 = ngẫu nhiên, 1 = hoàn hảo.
TP/FP/TN/FN	Dương thật / Dương giả / Âm thật / Âm giả. FN đắt nhất trong tín dụng.
Precision/Recall F_1/F_2	$\text{Precision} = TP/(TP+FP)$; $\text{Recall} = TP/(TP+FN)$. Trung bình điều hòa Precision–Recall; F_2 ưu tiên Recall gấp đôi Precision.
SHAP	Giá trị Shapley — phân tách dự báo thành đóng góp của từng đặc trưng.
Bagging/Boosting	Hai kiểu học tổ hợp: Bagging huấn luyện song song giảm phương sai; Boosting tuần tự giảm độ chệch.
Class Imbalance	Mất cân bằng lớp — lớp thiểu số chỉ chiếm 6,68%.
scale_pos_weight	Trọng số XGBoost nâng tầm lớp thiểu số.

1 Giới thiệu

1.1 Tính cấp thiết

Tỷ lệ nợ xấu của hệ thống ngân hàng Việt Nam cuối năm 2023 ở mức 4,55% [1], phản ánh áp lực rủi ro tín dụng ngày càng lớn. Quy trình thẩm định thủ công không mở rộng được theo quy mô hồ sơ; trong khi các mô hình chấm điểm tuyến tính cổ điển bỏ qua các tương tác phi tuyến giữa thu nhập, dư nợ và lịch sử trễ hạn.

Học máy học quy luật rủi ro từ dữ liệu lịch sử quy mô lớn và nắm bắt được các tương tác phi tuyến này. Tuy nhiên, các mô hình mạnh thường mang tính “hộp đen”. Hiệp ước Basel và quy định bảo vệ dữ liệu (GDPR, Điều 22) yêu cầu tổ chức tín dụng phải *giải thích được* lý do từ chối một hồ sơ [2, 10]. Phương pháp SHAP [3] giải quyết yêu cầu này bằng cách quy mỗi quyết định về đóng góp của từng đặc trưng.

1.2 Mục tiêu (SMART)

Bảng 1.1: Mục tiêu cụ thể và kết quả đạt được của đề án.


Mục tiêu	Chỉ tiêu	Kết quả
Xây dựng mô hình	$AUC \geq 0,87$	0,8714
So sánh 4 thuật toán	Bảng đầy đủ	Bảng 4.1
Thiết kế đặc trưng	≥ 2 đặc trưng mới vào top-5 SHAP	2 trong top-3
Tối ưu ngưỡng	Tối ưu theo F_2	$t = 0,625$, Recall 66,9%
Demo sản phẩm	Streamlit + SHAP	Đạt

1.3 Phạm vi

- **Dữ liệu:** *Give Me Some Credit* (Kaggle, 149.999 hồ sơ có nhãn trong `cs-training.csv`; `cs-test.csv` là tập nộp dự đoán, không có nhãn thật).
- **Mô hình:** bốn mô hình LR, DT, RF, XGBoost.
- **Không bao gồm:** mạng nơ-ron sâu, chấm điểm thời gian thực, tích hợp hệ thống.
- **Công nghệ:** Python 3.14, scikit-learn 1.8, XGBoost 3.2, SHAP 0.51.

1.4 Đóng góp chính và quy trình tổng quan

Đóng góp chính của đồ án gồm: (1) xây dựng đầy đủ quy trình từ khám phá dữ liệu đến demo sản phẩm; (2) thiết kế 4 đặc trưng mới có ý nghĩa nghiệp vụ, 2 trong số đó vào top-3 SHAP; (3) chuẩn hóa cách chọn ngưỡng triển khai theo F_2 ; (4) đóng gói thành ứng dụng web hỗ trợ dự báo đơn lẻ và hậu kiểm theo lô. Toàn bộ quy trình được tóm tắt trong [Hình 1.1](#).



Hình 1.1: Sơ đồ quy trình tổng quan của đồ án.

2 Cơ sở lý thuyết

Chương này trình bày nền tảng toán học của các mô hình và độ đo được sử dụng. Mục tiêu là làm rõ vì sao mỗi mô hình hoạt động, thay vì chỉ mô tả cách dùng.

2.1 Bài toán phân loại nhị phân

Định nghĩa 2.1 (Phân loại nhị phân). Cho không gian đặc trưng $\mathcal{X} \subseteq \mathbb{R}^p$ và nhãn $y \in \{0, 1\}$. Bài toán phân loại nhị phân là tìm hàm $f : \mathcal{X} \rightarrow [0, 1]$ ước lượng xác suất hậu nghiệm $f(\mathbf{x}) \approx \mathbb{P}(y = 1 \mid \mathbf{x})$. Quyết định cứng thu được qua một ngưỡng $t \in (0, 1)$:

$$\hat{y} = \mathbf{1}[f(\mathbf{x}) \geq t].$$

Mất cân bằng lớp. Trong bộ dữ liệu, tỷ lệ vỡ nợ chỉ 6,68%, tức tỷ lệ âm/dương xấp xỉ 14:1. Hệ quả là (i) độ chính xác (accuracy) trở nên vô nghĩa — một bộ phân loại luôn dự báo “không vỡ nợ” đã đạt 93,32% accuracy; và (ii) ngưỡng tối ưu thường khác xa 0,5. Vì vậy ta đánh giá bằng AUC, F_β và chi phí kỳ vọng thay vì accuracy (xem Mục 2.6).

2.2 Hồi quy Logistic

Hồi quy Logistic mô hình hóa xác suất hậu nghiệm bằng hàm sigmoid $\sigma(z) = \frac{1}{1 + e^{-z}}$ áp lên một tổ hợp tuyến tính của đặc trưng:

$$p_i := \mathbb{P}(y_i = 1 \mid \mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b) = \frac{1}{1 + \exp(-(\mathbf{w}^\top \mathbf{x}_i + b))}. \quad (2.1)$$

Tham số $(\mathbf{w}, b)$ được ước lượng theo nguyên lý hợp lý cực đại (MLE). Với giả thiết các quan sát độc lập tuân theo phân phối Bernoulli, hàm hợp lý là $\prod_i p_i^{y_i} (1 - p_i)^{1-y_i}$. Lấy logarit âm và chia cho N ta được hàm mất mát *cross-entropy* (log-loss):

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right]. \quad (2.2)$$

Mệnh đề 2.2 (Gradient và tính lồi). Đặt $X \in \mathbb{R}^{N \times p}$ là ma trận đặc trưng, $\mathbf{p} = (p_i)$, $\mathbf{y} = (y_i)$.

Khi đó

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{N} X^\top (\mathbf{p} - \mathbf{y}), \quad \nabla_{\mathbf{w}}^2 \mathcal{L} = \frac{1}{N} X^\top S X,$$

với $S = \text{diag}(p_i(1 - p_i)) \succeq 0$. Do đó $\mathcal{L}$ là hàm lồi theo $\mathbf{w}$, và mọi điểm dừng đều là cực tiểu toàn cục.

Chứng minh. Dùng $\sigma'(z) = \sigma(z)(1 - \sigma(z))$. Với một quan sát, $\partial \mathcal{L}_i / \partial \mathbf{w} = -(y_i - p_i) \mathbf{x}_i = (p_i - y_i) \mathbf{x}_i$; lấy trung bình cho công thức gradient. Đạo hàm thêm một lần: $\partial p_i / \partial \mathbf{w} = p_i(1 - p_i) \mathbf{x}_i$, suy ra Hessian $= \frac{1}{N} \sum_i p_i(1 - p_i) \mathbf{x}_i \mathbf{x}_i^\top = \frac{1}{N} X^\top S X$. Với mọi $\mathbf{v}$, $\mathbf{v}^\top X^\top S X \mathbf{v} = \sum_i p_i(1 - p_i) (\mathbf{x}_i^\top \mathbf{v})^2 \geq 0$ vì $p_i \in (0, 1)$. Vậy Hessian nửa xác định dương, $\mathcal{L}$ lồi. ■

Ưu/nhược. Nhanh, dễ giải thích (hệ số là log-odds), là baseline tốt; nhưng chỉ tạo biên quyết định tuyến tính nên khó nắm bắt tương tác phi tuyến mạnh.

2.3 Cây quyết định (CART)

Cây quyết định phân hoạch đệ quy không gian đặc trưng thành các vùng hình hộp, mỗi vùng gán một dự báo. Tại mỗi nút, thuật toán CART chọn cặp (đặc trưng, ngưỡng) làm *giảm độ vẩn* (impurity) nhiều nhất. Với một nút t chứa tỉ lệ lớp $p_{k|t}$, hai độ vẩn thông dụng là

$$\underbrace{G(t) = 1 - \sum_k p_{k|t}^2}_{\text{Gini}}, \quad \underbrace{H(t) = - \sum_k p_{k|t} \log_2 p_{k|t}}_{\text{Entropy}}. \quad (2.3)$$

Một phép chia s tách nút cha thành nút con trái/phải với số mẫu N_L, N_R ($N = N_L + N_R$). Độ giảm độ vẩn (information gain) là

$$\Delta I(s, t) = I(t) - \frac{N_L}{N} I(t_L) - \frac{N_R}{N} I(t_R), \quad (2.4)$$

và CART chọn $s^* = \arg \max_s \Delta I(s, t)$. Cây dừng khi đạt độ sâu tối đa hoặc số mẫu lá tối thiểu.

Ưu/nhược. Trực quan, mô tả được logic quyết định; nhưng một cây đơn dễ quá khớp (overfit) và có phương sai cao — đây chính là động lực cho mô hình tổ hợp.

2.4 Bagging và Rừng ngẫu nhiên

Rừng ngẫu nhiên huấn luyện B cây trên các mẫu bootstrap khác nhau và lấy trung bình dự báo. Cơ chế giảm phương sai được làm rõ bởi kết quả sau.

Mệnh đề 2.3 (Giảm phương sai nhờ trung bình hóa). *Giả sử B cây cho dự báo $\{Z_b\}$ cùng phân phối, mỗi cái có phương sai σ^2 và tương quan từng cặp $\rho \geq 0$. Khi đó phương sai của dự báo*

trung bình $\bar{Z} = \frac{1}{B} \sum_b Z_b$ là

$$\text{Var}(\bar{Z}) = \rho \sigma^2 + \frac{1-\rho}{B} \sigma^2 \xrightarrow{B \rightarrow \infty} \rho \sigma^2. \quad (2.5)$$

Chứng minh. $\text{Var}(\bar{Z}) = \frac{1}{B^2} [\sum_b \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'})] = \frac{1}{B^2} [B\sigma^2 + B(B-1)\rho\sigma^2] = \frac{\sigma^2}{B} + \frac{B-1}{B} \rho\sigma^2$, rút gọn ra **công thức (2.5)**. ■

Số hạng thứ hai $\frac{1-\rho}{B} \sigma^2$ triệt tiêu khi tăng B , nhưng số hạng $\rho\sigma^2$ thì không. Vì thế Rừng ngẫu nhiên còn *lấy ngẫu nhiên một tập con đặc trưng* tại mỗi phép chia để *giảm* ρ giữa các cây — đó là điểm khác biệt cốt lõi so với bagging thuần. Kết quả: ổn định hơn cây đơn, kháng nhiễu tốt, đổi lại khó diễn giải trực tiếp.

2.5 Gradient Boosting và XGBoost

Khác với bagging (song song), boosting xây mô hình cộng dồn theo chuỗi: cây thứ t sửa phần sai số còn lại của tổ hợp $t-1$ cây trước. Dự báo sau t vòng là $\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)$, với f_t là một cây hồi quy. XGBoost cực tiểu hàm mục tiêu *có chính quy hóa*:

$$\mathcal{L}^{(t)} = \sum_{i=1}^N l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2, \quad (2.6)$$

trong đó T là số lá, $\mathbf{w}$ là véc-tơ trọng số lá, $\gamma, \lambda \geq 0$ kiểm soát độ phức tạp. Khai triển Taylor bậc hai quanh $\hat{y}^{(t-1)}$ với $g_i = \partial_{\hat{y}} l$, $h_i = \partial_{\hat{y}}^2 l$:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^N \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2 \right] + \Omega(f_t) + \text{const}. \quad (2.7)$$

Định lý 2.4 (Trọng số lá tối ưu và độ lợi phép chia). Với một cấu trúc cây cố định, gọi I_j là tập mẫu rơi vào lá j , và đặt $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$. Khi đó trọng số lá tối ưu và giá trị mục tiêu tối ưu tương ứng là

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \tilde{\mathcal{L}}^{(t)} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T. \quad (2.8)$$

Độ lợi (gain) khi tách một lá thành hai lá trái/phải là

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma. \quad (2.9)$$

Chứng minh. Vì một cây gán cùng một trọng số w_j cho mọi mẫu trong lá j , nhóm tổng theo lá: $\mathcal{L}^{(t)} = \sum_{j=1}^T [G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2] + \gamma T$. Đây là tam thức bậc hai theo w_j với hệ số bậc hai

đương; cực tiểu đạt tại $w_j^* = -G_j/(H_j + \lambda)$. Thế lại được $\tilde{\mathcal{L}}^{(t)} = -\frac{1}{2} \sum_j G_j^2/(H_j + \lambda) + \gamma T$. Độ lợi của phép chia là chênh lệch giá trị mục tiêu trước và sau khi tách, cho ra **công thức (2.9)**.

■

Công thức **công thức (2.9)** chính là tiêu chí XGBoost dùng để chọn điểm chia: nó thường cho phép chia làm giảm mục tiêu và phạt γ cho mỗi lá mới, tạo cơ chế cắt tỉa tự nhiên. Việc dùng cả g_i và h_i (Newton bậc hai) khiến XGBoost hội tụ nhanh và ổn định hơn boosting bậc nhất.

2.6 Độ đo đánh giá

Từ ma trận nhầm lẫn (TP, FP, FN, TN) định nghĩa Precision = $\frac{TP}{TP+FP}$, Recall = $\frac{TP}{TP+FN}$. Tổng quát hóa qua trung bình điều hòa có trọng số là F_β :

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}}. \quad (2.10)$$

Tham số β đặt tầm quan trọng của Recall gấp β lần Precision; ta chọn $\beta = 2$ vì trong tín dụng, bỏ sót người vỡ nợ (FN) tốn kém hơn từ chối nhầm (FP).

Định lý 2.5 (Diễn giải xác suất của AUC). Gọi $\mathbf{x}^+$ là một mẫu dương và $\mathbf{x}^-$ là một mẫu âm lấy ngẫu nhiên độc lập. Khi đó diện tích dưới đường cong ROC bằng xác suất mô hình xếp mẫu dương cao hơn mẫu âm:

$$\text{AUC} = \mathbb{P}(f(\mathbf{x}^+) > f(\mathbf{x}^-)) + \frac{1}{2} \mathbb{P}(f(\mathbf{x}^+) = f(\mathbf{x}^-)). \quad (2.11)$$

Phác thảo. Đường ROC là đồ thị $\text{TPR}(t)$ theo $\text{FPR}(t)$ khi quét ngưỡng t . Đổi biến, $\text{AUC} = \int_0^1 \text{TPR} d(\text{FPR}) = \int \mathbb{P}(f(\mathbf{x}^+) > t) d\mathbb{P}(f(\mathbf{x}^-) \leq t)$, chính là $\mathbb{P}(f(\mathbf{x}^+) > f(\mathbf{x}^-))$ (cộng nửa khối lượng tại các điểm bằng nhau). Đây cũng là thống kê U Mann–Whitney chuẩn hóa, nên AUC bất biến với mọi phép biến đổi đơn điệu của điểm số. ■

Nhận xét 2.6 (Ngưỡng Bayes tối ưu theo chi phí). Nếu chi phí của một FP là c_{FP} và của một FN là c_{FN} , quy tắc cực tiểu chi phí kỳ vọng là dự báo dương khi $p > t^*$ với $t^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$. Chi phí FN càng lớn thì ngưỡng càng thấp.

2.7 Diễn giải mô hình bằng SHAP

SHAP gán cho mỗi đặc trưng i một đóng góp ϕ_i vào chênh lệch giữa dự báo và giá trị nền, dựa trên *giá trị Shapley* từ lý thuyết trò chơi hợp tác. Với hàm giá trị $v(S)$ là dự báo kỳ vọng khi chỉ

biết tập đặc trưng S :

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [v(S \cup \{i\}) - v(S)]. \quad (2.12)$$

Giá trị Shapley là cách phân bổ *duy nhất* thỏa đồng thời bốn tiên đề: tính hiệu quả ($\sum_i \phi_i$ bằng chênh lệch dự báo), đối xứng, đặc trưng vô dụng có $\phi_i = 0$, và tính cộng tính. Với mô hình cây, TreeExplainer tính **công thức (2.12)** chính xác theo thời gian đa thức, tránh chi phí tổ hợp $2^{|F|}$.


2.8 Hiệu chỉnh xác suất và kiểm định thống kê

Điểm số của cây boosting thường không phải xác suất hiệu chỉnh tốt. *Platt scaling* hiệu chỉnh bằng một hồi quy logistic một biến trên điểm số: $\hat{p} = \sigma(a f(\mathbf{x}) + b)$. Chất lượng hiệu chỉnh đo bằng điểm Brier $BS = \frac{1}{N} \sum_i (\hat{p}_i - y_i)^2$ và sai số hiệu chỉnh kỳ vọng ECE. Để kiểm tra chênh lệch AUC giữa hai mô hình *tương quan* (cùng tập kiểm tra) có ý nghĩa thống kê hay không, ta dùng kiểm định DeLong.

3 Dữ liệu và Tiền xử lý

3.1 Khám phá dữ liệu (EDA)

Bộ dữ liệu gồm 149.999 hồ sơ (sau khi loại 1 dòng có tuổi = 0), 10 đặc trưng gốc. Tỷ lệ vỡ nợ 6,68% (9.951 dương / 140.048 âm) — mất cân bằng mạnh (Hình 3.1). Một số biến tài chính như `RevolvingUtilization` và `DebtRatio` có phân phối lệch phải nặng, cần lưu ý các giá trị cực trị (Hình 3.2).



Hình 3.1: Phân bố lớp mục tiêu — mất cân bằng $\approx 14:1$.


Nhóm biến trễ hạn (30–59, 60–89, 90+ ngày) liên hệ mạnh nhất với rủi ro vỡ nợ (Hình 3.4), gợi ý giá trị của các đặc trưng tổng hợp từ nhóm này.

3.2 Xử lý giá trị thiếu


Hai biến có khuyết thiếu đáng kể: `MonthlyIncome` (19,8%) và số người phụ thuộc. Ta dùng KNN Imputer ($k = 5$): mỗi giá trị thiếu được điền bằng trung bình của 5 hồ sơ gần nhất theo khoảng cách Euclid trên các chiều quan sát được. So với điền trung vị, KNN giữ được cấu trúc tương quan giữa các biến (Hình 3.5).

3.3 Chuẩn hóa


Áp dụng `StandardScaler` cho Hồi quy Logistic để gradient descent ổn định (đưa các đặc trưng về cùng thang đo). Các mô hình dựa trên cây (DT, RF, XGBoost) bất biến với phép biến đổi đơn điệu nên không cần chuẩn hóa.




Hình 3.2: Phân phối đơn biến của các đặc trưng gốc.



Hình 3.3: Ma trận tương quan giữa các đặc trưng.



Hình 3.4: Phân tích nhóm biến trễ hạn theo tỷ lệ vỡ nợ.



Hình 3.5: So sánh phân phối trước/sau khi điền khuyết bằng KNN.

3.4 Thiết kế đặc trưng


Bốn đặc trưng được thiết kế dựa trên hiểu biết nghiệp vụ:

1. $\text{TotalDelinquencyScore} = 3 \times (90+) + 2 \times (60-89) + 1 \times (30-59)$ — phạt nặng trễ hạn kéo dài.
2. $\text{FinancialStressIndex} = \text{RevolvingUtil} \times \text{TotalDelinquencyScore}$ — dùng hết hạn mức và trễ hạn = áp lực cao.
3. $\text{AbsoluteMonthlyDebt} = \text{DebtRatio} \times \text{MonthlyIncome}$ — quy dư nợ tương đối về giá trị tuyệt đối.
4. $\text{DelinquencySeverityBalance} = (30-59) - (90+)$ — cân bằng mức độ trễ hạn trên ảnh chụp tĩnh.

Hiệu quả của thiết kế này được kiểm chứng ở [Mục 4.3](#).

3.5 Mất cân bằng lớp

Để xử lý mất cân bằng, ta dùng $\text{scale_pos_weight} = n_-/n_+ \approx 14$ trong XGBoost (nâng trọng số lớp thiểu số) và khảo sát SMOTE (sinh mẫu thiểu số tổng hợp, [Hình 3.6](#)). Cuối cùng chọn trọng số lớp vì giữ được phân phối gốc và tránh rò rỉ dữ liệu khi kết hợp với kiểm định chéo.



Hình 3.6: Minh họa SMOTE sinh mẫu lớp thiểu số.

4 Thực nghiệm và Đánh giá

4.1 Thiết kế thử nghiệm

Chia dữ liệu theo tỷ lệ 70/15/15: huấn luyện 104.999, kiểm định 22.500, kiểm tra 22.500 hồ sơ, dùng phân tầng (stratified) để giữ tỷ lệ lớp. Lựa chọn siêu tham số bằng kiểm định chéo phân tầng $k = 5$.

4.2 So sánh mô hình

XGBoost cho AUC cao nhất và thỏa mục tiêu $AUC \geq 0,87$ (Bảng 4.1, Hình 4.1). Đường ROC/PR của bốn mô hình được so sánh trong Hình 4.2.

Bảng 4.1: Kết quả tổng hợp bốn mô hình trên tập kiểm tra.

Mô hình	AUC-ROC	F1	Recall	Precision	Thời gian (s)
Logistic Regression	0,8432	0,398	41,2%	39,8%	1,23
Decision Tree (CART)	0,8579	0,421	48,7%	40,1%	0,18
Random Forest	0,8703	0,437	52,1%	40,5%	5,32
XGBoost	0,8714	0,442	52,6%	41,3%	2,18


4.3 Diễn giải SHAP

Áp dụng TreeExplainer cho XGBoost. Hai đặc trưng tự thiết kế (FinancialStressIndex, TotalDelinquencyScore) lọt vào top-3 (Bảng 4.2, Hình 4.3), xác nhận hiệu quả của thiết kế đặc trưng.

4.4 Tối ưu ngưỡng theo F_2

Theo Nhận xét 2.6, ngưỡng Bayes với $c_{FP} = 500$, $c_{FN} = 11.250$ là $t^* = \frac{500}{500+11.250} \approx 0,043$ — quá thấp (từ chối $\sim 74\%$ hồ sơ), không thực dụng. Thay vào đó ta tối ưu trực tiếp F_2 (công thức (2.10), $\beta = 2$): quét $t \in [0,05; 0,95]$ cho cực đại tại $t = 0,625$ với Recall 66,9%, Precision 29,9%, $F_2 = 0,537$ (Bảng 4.3, Hình 4.4).

So với ngưỡng F_1 -optimal, ngưỡng F_2 giảm khoảng 2,01 triệu USD chi phí trong khi vẫn ưu tiên phát hiện hồ sơ rủi ro.




Hình 4.1: So sánh tổng hợp các chỉ số giữa bốn mô hình.

Bảng 4.2: Năm đặc trưng quan trọng nhất theo |SHAP| trung bình.


Hạng	Đặc trưng	SHAP
1	RevolvingUtilizationOfUnsecuredLines	0,251
2	<i>FinancialStressIndex</i> (tự thiết kế)	0,198
3	<i>TotalDelinquencyScore</i> (tự thiết kế)	0,187
4	NumberOfOpenCreditLinesAndLoans	0,142
5	Age	0,108

Bảng 4.3: So sánh các ngưỡng trên tập kiểm tra (22.500 hồ sơ).


Ngưỡng	Recall	Precision	F_2	Chi phí (tr.USD)
Mặc định (0,50)	77,5%	22,2%	0,518	5,84
F_2 -optimal (0,625)	66,9%	29,9%	0,537	6,78
F_1 -optimal (0,77)	51,6%	39,4%	0,486	8,79
Bayes-optimal (0,043)	99,2%	6,9%	0,265	34,50



Hình 4.2: Đường ROC của bốn mô hình trên tập kiểm tra.




Hình 4.3: Tầm quan trọng đặc trưng theo giá trị SHAP.




Hình 4.4: Tối ưu ngưỡng vận hành theo F_2 .

4.5 Phân tích lỗi và hiệu chỉnh xác suất

Phần lớn lỗi tập trung ở vùng điểm rủi ro sát ngưỡng — các hồ sơ có tín hiệu mâu thuẫn (Hình 4.5); vùng này phù hợp để chuyển sang rà soát thủ công. Sau Platt scaling, điểm Brier giảm từ 0,0582 xuống 0,0478 và ECE từ 3,2% xuống 1,9%, tức xác suất dự báo gần thực tế hơn (Hình 4.6). Kiểm định DeLong xác nhận chênh lệch AUC giữa XGBoost và Random Forest là nhỏ và không có ý nghĩa thống kê mạnh, nhất quán với Bảng 4.1.



Hình 4.5: Phân bố điểm rủi ro của hai lớp quanh ngưỡng quyết định.




Hình 4.6: Đường hiệu chỉnh xác suất trước và sau Platt scaling.

5 Sản phẩm — Ứng dụng Streamlit

5.1 Kiến trúc hệ thống

Ứng dụng được đóng gói thành một web app Streamlit với kiến trúc tách lớp như [Hình 5.1](#): lớp giao diện nhận đầu vào, lớp xử lý nạp mô hình đã lưu và bộ tiền xử lý, lớp giải thích sinh biểu đồ SHAP. Mô hình và TreeExplainer được nạp một lần và lưu đệm để tối ưu hiệu năng.



Hình 5.1: Kiến trúc lớp của ứng dụng Streamlit.

5.2 Tính năng chính

- **Tab 1 — Dự báo đơn lẻ:** nhập thông tin khách hàng, hiển thị xác suất vỡ nợ và quyết định (Duyệt/Từ chối) kèm biểu đồ SHAP waterfall giải thích.
- **Tab 2 — Đánh giá theo lô:** tải lên CSV/XLSX, dự báo theo lô, cho chọn ngưỡng (mặc định 0,625). Nếu file có cột nhãn thật `SeriousDlqin2yrs`, ứng dụng tính AUC, Recall, Precision, F_2 , ROC/PR, ma trận nhầm lẫn và tác động chi phí, đồng thời tóm tắt theo phân khúc thu nhập và nhóm tuổi.

Ứng dụng demo: <https://doandanhlong-loan-prediction.streamlit.app>.


5.3 Chạy thử hậu kiểm theo lô

Để kiểm tra chức năng hậu kiểm, đồ án tạo `batch_demo_from_training_5000.csv` (5.000 hồ sơ, 334 vỡ nợ, giữ tỷ lệ 6,68%). Kết quả tại ngưỡng $t = 0,625$ cho trong [Bảng 5.1](#); phân bố và ma trận nhầm lẫn ở [Hình 5.2](#).

Lưu ý: đây là mô phỏng hậu kiểm bằng dữ liệu huấn luyện có nhãn. Trong vận hành thật, nhãn thật chỉ xuất hiện sau kỳ quan sát. Không dùng tập kiểm tra Kaggle để hậu kiểm vì tập này không có nhãn thật.

Bảng 5.1: Kết quả hậu kiểm theo lô tại ngưỡng $t = 0,625$.


Chỉ số	Giá trị
AUC-ROC	0,8780
Recall	68,26%
Precision	29,53%
F_2 -score	0,5408
TP / FP / FN / TN	228 / 544 / 106 / 4122
Tỷ lệ từ chối	15,44%
Chi phí tại ngưỡng	1.464.500 USD
Chi phí nếu duyệt tất cả	3.757.500 USD
Tiết kiệm mô phỏng	2.293.000 USD



Hình 5.2: Ma trận nhầm lẫn (trái) và tác động chi phí (phải) trên demo theo lô.

5.4 Kết quả thử nghiệm Kaggle

Thử nghiệm đạt Public AUC = 0,85785 và Private AUC = 0,86482, khá gần AUC nội bộ 0,8714 — cho thấy mô hình tổng quát hóa ổn trên tập đánh giá ngoài (Hình 5.3).



Hình 5.3: Kết quả thử nghiệm trên Kaggle.

6 Kết luận và Hướng phát triển

6.1 Kết luận

1. XGBoost đạt $AUC = 0,8714$, vượt mục tiêu $0,87$.
2. Thiết kế đặc trưng có chủ đích: 2 đặc trưng tự thiết kế vào top-3 SHAP.
3. Ngưỡng F_2 -optimal ($0,625$) cân bằng Recall–Precision phù hợp tín dụng và giảm chi phí so với ngưỡng F_1 .
4. SHAP giải thích từng quyết định, đáp ứng yêu cầu minh bạch (Basel III, GDPR).

6.2 Hướng phát triển

- **Dữ liệu:** kết hợp dữ liệu tín dụng Việt Nam (CIC, SBV); chấm điểm thời gian thực.
- **Mô hình:** mạng nơ-ron có cơ chế attention; mô hình hóa chuỗi thời gian (LSTM); meta-learner.
- **Giải thích:** giải thích phản thực (counterfactual); hồ sơ tương tự (prototype).
- **Vận hành:** thử nghiệm A/B cho ngưỡng; giám sát trôi dữ liệu; vòng phản hồi cập nhật mô hình.

Tài liệu tham khảo


- [1] Ngân hàng Nhà nước Việt Nam (2024). *Báo cáo tình hình ngân hàng 2023*. <https://www.sbv.gov.vn>.
- [2] Basel Committee on Banking Supervision (2018). *Basel III: Finalising post-crisis reforms*. Bank for International Settlements.
- [3] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD*.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12, 2825–2830.
- [6] Kaggle (2011). *Give Me Some Credit*. <https://www.kaggle.com/c/GiveMeSomeCredit>.
- [7] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [8] DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing areas under two or more correlated ROC curves. *Biometrics*, 44(3), 837–845.
- [9] Platt, J. (1999). Probabilistic outputs for support vector machines. *Advances in Large Margin Classifiers*.
- [10] European Union (2018). *General Data Protection Regulation (EU) 2016/679*.
- [11] Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.
- [12] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.

A Siêu tham số XGBoost


```
{  
  'n_estimators': 200,      'max_depth': 6,  
  'learning_rate': 0.05,    'subsample': 0.8,  
  'colsample_bytree': 0.8,  'scale_pos_weight': 14.05, # n_neg/n_pos  
  'objective': 'binary:logistic', 'random_state': 42  
}
```

B Hình kỹ thuật bổ sung


Các hình dưới đây phục vụ kiểm tra sâu hơn, không lặp lại hình ở phần chính.



Hình B.1: Thông tin tương hỗ giữa đặc trưng và nhãn.



Hình B.2: Đồ thị phụ thuộc SHAP cho đặc trưng chính.



Hình B.3: Đường cong học của XGBoost.

DeLong Test — XGBoost vs Random Forest (same test set)

Model A	Model B	AUC A	AUC B	Δ AUC	z-stat	p-value	Kết luận
XGBoost	RF	0.8714	0.8671	+0.0043	4.1833	0.0000	Sig. ($p < 0.05$)

Hình B.4: Tóm tắt kiểm định DeLong giữa các mô hình.