

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



BÁO CÁO ĐỒ ÁN I

DỰ BÁO RỦI RO VỠ NỢ
TÍN DỤNG BẰNG MACHINE
LEARNING

Giảng viên hướng dẫn: TS. Nguyễn Cảnh Nam

Sinh viên thực hiện: Đoàn Danh Long

Mã số sinh viên: 20237354

Học kỳ: 2025.2

Hà Nội, tháng 6 năm 2026

Lời mở đầu

Hoạt động tín dụng là xương sống của hệ thống ngân hàng, nhưng đi kèm với nó là rủi ro vỡ nợ — khi người vay mất khả năng trả nợ. Việc đánh giá rủi ro chính xác trước khi cấp tín dụng quyết định trực tiếp đến chất lượng tài sản và sự an toàn của tổ chức cho vay. Quy trình thẩm định thủ công truyền thống vừa tốn kém, vừa khó mở rộng quy mô, vừa mang tính chủ quan; trong khi các mô hình chấm điểm tuyến tính cổ điển (như FICO) bỏ qua phần lớn các tương tác phi tuyến giữa các yếu tố tài chính.

Học máy (Machine Learning) cung cấp một hướng tiếp cận khác: học quy luật rủi ro trực tiếp từ dữ liệu lịch sử của hàng trăm nghìn hồ sơ vay, nắm bắt các quan hệ phi tuyến phức tạp mà mô hình tuyến tính không biểu diễn được. Tuy nhiên, một mô hình tốt trong bài toán tín dụng không chỉ cần *chính xác* mà còn phải *giải thích được* (do ràng buộc pháp lý khi từ chối khách hàng) và *phù hợp với chi phí kinh doanh* (vì bỏ sót một người sẽ vỡ nợ tốn kém hơn nhiều so với từ chối nhầm một người tốt).

Báo cáo này trình bày một cách hệ thống toàn bộ quy trình xây dựng một hệ thống dự báo rủi ro vỡ nợ trên bộ dữ liệu *Give Me Some Credit* (Kaggle): từ cơ sở lý thuyết của các mô hình phân loại, khám phá và tiền xử lý dữ liệu, thiết kế đặc trưng, huấn luyện và so sánh bốn mô hình (Hồi quy Logistic, Cây quyết định, Rừng ngẫu nhiên, XGBoost), đến diễn giải mô hình bằng giá trị SHAP, tối ưu ngưỡng quyết định theo chi phí, và đóng gói thành một ứng dụng web hoàn chỉnh. Toàn bộ nội dung được sắp xếp từ cơ sở lý thuyết đến thực nghiệm và ứng dụng, nhằm tạo thành một bản tổng hợp nhất quán và dễ theo dõi.

Lời cảm ơn

Em xin gửi lời cảm ơn chân thành đến Giảng viên hướng dẫn — Thầy Nguyễn Cảnh Nam, Khoa Toán–Tin, Trường Đại học Bách Khoa Hà Nội — đã tận tình hướng dẫn, góp ý và định hướng trong suốt quá trình thực hiện đồ án.

Em cũng xin cảm ơn gia đình và bạn bè đã luôn động viên, tạo điều kiện thuận lợi để em có thể hoàn thành đồ án đúng tiến độ. Dù đã cố gắng hết sức, báo cáo chắc chắn còn nhiều thiếu sót. Em rất mong nhận được nhận xét và góp ý từ Thầy để tiếp tục cải thiện trong những nghiên cứu tiếp theo.

Hà Nội, tháng 6 năm 2026 — Đoàn Danh Long

Tóm tắt

Báo cáo trình bày nghiên cứu ứng dụng học máy vào bài toán dự báo rủi ro vỡ nợ tín dụng, sử dụng bộ dữ liệu *Give Me Some Credit* (Kaggle, 149.999 hồ sơ vay). Bốn mô hình được xây dựng và đánh giá trên tập kiểm tra: Hồi quy Logistic (AUC = 0,8630), Cây quyết định (0,8579), Rừng ngẫu nhiên (0,8671) và XGBoost (0,8714). XGBoost vượt mục tiêu (AUC > 0,87) nhờ thiết kế đặc trưng có chủ đích: hai đặc trưng tự thiết kế chiếm vị trí số 1 và số 3 theo giá trị SHAP. Ngưỡng quyết định được tối ưu theo F_2 tại $t = 0,625$, đạt Recall 66,9% với tỷ lệ từ chối 14,9%, giảm chi phí ước tính khoảng 2,14 triệu USD so với ngưỡng tối ưu theo F_1 . Xác suất đầu ra được hiệu chỉnh bằng Platt scaling, đưa sai số hiệu chỉnh ECE từ 25,0% về 0,65%. Cuối cùng, toàn bộ pipeline được đóng gói thành một ứng dụng web triển khai thử nghiệm, cho phép chạy trực tiếp mô hình trên dữ liệu mới: dự báo đơn lẻ kèm giải thích SHAP và hậu kiểm theo lô.

Từ khóa: dự báo vỡ nợ, XGBoost, SHAP, F_β -score, dữ liệu mất cân bằng.

Mục lục

Lời mở đầu	i
Lời cảm ơn	ii
Tóm tắt	iii
Bảng thuật ngữ viết tắt	vii
1 Giới thiệu	1
1.1 Tính cấp thiết	1
1.2 Mục tiêu (SMART)	1
1.3 Phạm vi	1
1.4 Đóng góp chính và quy trình tổng quan	2
2 Cơ sở lý thuyết	3
2.1 Bài toán phân loại nhị phân	3
2.2 Hồi quy Logistic	4
2.3 Cây quyết định (CART)	5
2.4 Bagging và Rừng ngẫu nhiên	5
2.5 Gradient Boosting và XGBoost	6
2.6 Độ đo đánh giá	7
2.7 Diễn giải mô hình bằng SHAP	8
2.8 Hiệu chỉnh xác suất và kiểm định thống kê	9
3 Dữ liệu và Tiền xử lý	10
3.1 Khám phá dữ liệu (EDA)	10
3.2 Xử lý giá trị thiếu	11
3.3 Chuẩn hóa	14
3.4 Thiết kế đặc trưng	15
3.5 Mất cân bằng lớp	16
4 Thực nghiệm và Đánh giá	17
4.1 Thiết kế thử nghiệm	17
4.2 So sánh mô hình	17
4.3 Diễn giải SHAP	18

4.4	Tối ưu ngưỡng theo F_2	20
4.5	Phân tích lỗi và hiệu chỉnh xác suất	21
5	Triển khai mô hình thành ứng dụng	24
5.1	Kiến trúc hệ thống	24
5.2	Hai chế độ vận hành	24
5.3	Chạy thử hậu kiểm theo lô	25
5.4	Kiểm chứng ngoài: nộp thử Kaggle	26
6	Kết luận và Hướng phát triển	27
6.1	Kết luận	27
6.2	Hạn chế	27
6.3	Hướng phát triển	28
	Tài liệu tham khảo	29
A	Siêu tham số XGBoost	31
B	Hình kỹ thuật bổ sung	32

Danh sách hình vẽ

1.1	Sơ đồ quy trình tổng quan của đồ án.	2
3.1	Phân bố lớp mục tiêu — mất cân bằng $\approx 14:1$	11
3.2	Phân phối đơn biến của các đặc trưng gốc.	12
3.3	Ma trận tương quan giữa các đặc trưng.	13
3.4	Phân tích nhóm biến trễ hạn theo tỷ lệ vỡ nợ.	13
3.5	Trái: điền trung vị tạo đỉnh nhọn nhân tạo tại 5.400 USD. Phải: tỷ lệ vỡ nợ theo trạng thái thiếu thu nhập — khuyết thiếu mang thông tin.	14
4.1	Đường ROC của bốn mô hình trên tập kiểm tra.	19
4.2	Tầm quan trọng đặc trưng theo giá trị SHAP.	20
4.3	Tối ưu ngưỡng vận hành theo F_2	21
4.4	Trái: phân bố điểm dự báo theo nhãn thật. Phải: nhóm vỡ nợ tách theo bất đúng/bỏ sót tại ngưỡng 0,625.	22
4.5	Biểu đồ độ tin cậy và điểm Brier của bốn mô hình (trước hiệu chỉnh).	22
4.6	XGBoost trước/sau hiệu chỉnh Platt scaling trên tập kiểm tra.	23
5.1	Kiến trúc lớp của ứng dụng Streamlit.	24
5.2	Ma trận nhầm lẫn (trái) và tác động chi phí (phải) trên lần chạy thử theo lô.	26
5.3	Kết quả nộp thử trên Kaggle.	26
B.1	Minh họa cơ chế SMOTE sinh mẫu lớp thiểu số.	32
B.2	Thông tin tương hỗ giữa đặc trưng và nhãn.	33
B.3	Đồ thị phụ thuộc SHAP cho đặc trưng chính.	33
B.4	Đường cong học của XGBoost.	33
B.5	Kiểm định DeLong cho cặp XGBoost–Random Forest trên tập kiểm tra.	34

Bảng thuật ngữ viết tắt

Báo cáo ưu tiên dùng tiếng Việt; các thuật ngữ tiếng Anh chỉ giữ lại khi là tên riêng của phương pháp/công cụ hoặc khi cộng đồng chuyên môn dùng nguyên gốc. Mỗi thuật ngữ như vậy được giải nghĩa ngay lần xuất hiện đầu tiên và tổng hợp lại trong bảng dưới đây.

Thuật ngữ	Giải nghĩa
Vỡ nợ (default)	Người vay mất khả năng trả nợ; trong bộ dữ liệu là trễ hạn nghiêm trọng (≥ 90 ngày) trong vòng 2 năm.
Accuracy	Độ chính xác tổng thể — tỷ lệ dự báo đúng trên toàn bộ mẫu. Vô nghĩa khi dữ liệu mất cân bằng nặng.
ROC / AUC-ROC	ROC: đường cong tỷ lệ dương thật theo tỷ lệ dương giả khi quét ngưỡng. AUC: diện tích dưới đường ROC — đo khả năng <i>xếp hạng</i> rủi ro; 0,5 = đoán ngẫu nhiên, 1 = hoàn hảo.
TP/FP/TN/FN	Dương thật / Dương giả / Âm thật / Âm giả. Trong tín dụng, FN (bỏ sót người sẽ vỡ nợ) gây tổn thất lớn nhất.
Precision / Recall	Độ chuẩn xác = $TP/(TP+FP)$: trong số bị từ chối, bao nhiêu thật sự rủi ro. Độ phủ = $TP/(TP+FN)$: trong số sẽ vỡ nợ, bắt được bao nhiêu.
F_1 / F_β	Trung bình điều hòa của Precision–Recall; F_2 coi Recall quan trọng gấp đôi Precision.
Ngưỡng (threshold)	Mức cắt t trên xác suất dự báo để chuyển thành quyết định Duyệt/Từ chối.
Baseline	Mô hình mốc đơn giản dùng làm chuẩn so sánh cho các mô hình phức tạp hơn.
Overfitting (quá khớp)	Mô hình học thuộc cả nhiễu của tập huấn luyện nên kém trên dữ liệu mới.
Bias / Variance	Độ chệch / phương sai — hai nguồn sai số: mô hình quá đơn giản (chệch cao) hoặc quá nhạy với dữ liệu huấn luyện (phương sai cao).

Thuật ngữ	Giải nghĩa
Bagging / Boosting	Hai kiểu học tổ hợp (ensemble): Bagging huấn luyện nhiều mô hình song song trên các mẫu bootstrap rồi lấy trung bình (giảm phương sai); Boosting xây tuần tự, mô hình sau sửa lỗi mô hình trước (giảm độ chệch).
Bootstrap	Lấy mẫu lại có hoàn lại từ tập dữ liệu gốc, cùng kích thước, để tạo các tập huấn luyện khác nhau.
Cross-entropy / log-loss	Hàm mất mát đo độ lệch giữa xác suất dự báo và nhãn thật, suy ra từ nguyên lý hợp lý cực đại.
Cross-validation (kiểm định chéo)	Chia tập huấn luyện thành k phần, lần lượt giữ 1 phần để đánh giá — ước lượng hiệu năng ổn định hơn một lần chia duy nhất.
Stratified (phân tầng)	Cách chia dữ liệu giữ nguyên tỷ lệ các lớp trong mỗi phần chia.
EDA	Exploratory Data Analysis — khám phá dữ liệu bằng thống kê mô tả và trực quan hóa trước khi mô hình hóa.
Feature engineering	Thiết kế đặc trưng — tạo biến mới từ biến gốc dựa trên hiểu biết nghiệp vụ để mô hình học dễ hơn.
Imputation (điền khuyết)	Điền giá trị hợp lý vào ô dữ liệu bị thiếu; KNN Imputer điền bằng trung bình của k hồ sơ giống nhất.
RobustScaler	Phép chuẩn hóa dùng trung vị và khoảng tứ phân vị (IQR) thay cho trung bình/độ lệch chuẩn — bền vững trước giá trị cực trị.
Class imbalance	Mất cân bằng lớp — lớp thiểu số (vỡ nợ) chỉ chiếm 6,68% số hồ sơ.
SMOTE	Kỹ thuật sinh thêm mẫu lớp thiểu số tổng hợp bằng nội suy giữa các mẫu thật lân cận.
scale_pos_weight	Tham số của XGBoost nhân trọng số lỗi của lớp dương (vỡ nợ) trong hàm mất mát, bù lại sự thiếu số.
Gini / Entropy	Hai độ đo độ pha tạp (impurity) của một nút trên cây quyết định — nút càng “thuần” một lớp thì giá trị càng thấp.
Information gain	Độ giảm độ pha tạp sau một phép chia — tiêu chí chọn điểm chia của cây quyết định.

Thuật ngữ	Giải nghĩa
Log-odds	Logarit của tỷ số $p/(1-p)$; trong hồi quy Logistic, log-odds là hàm tuyến tính của đặc trưng.
MLE	Maximum Likelihood Estimation — ước lượng hợp lý cực đại: chọn tham số làm cho dữ liệu quan sát có xác suất xuất hiện lớn nhất.
SHAP	SHapley Additive exPlanations — phân tách mỗi dự báo thành tổng đóng góp của từng đặc trưng, dựa trên giá trị Shapley của lý thuyết trò chơi.
TreeExplainer	Thuật toán tính chính xác giá trị SHAP cho mô hình cây trong thời gian đa thức.
Calibration (hiệu chỉnh xác suất)	Làm cho điểm số mô hình khớp với tần suất vỡ nợ thực tế (dự báo 0,3 thì khoảng 30% hồ sơ như vậy vỡ nợ thật).
Platt scaling	Phương pháp hiệu chỉnh xác suất bằng một hồi quy logistic một biến áp lên điểm số của mô hình gốc.
Brier score / ECE	Hai độ đo chất lượng hiệu chỉnh: trung bình bình phương sai lệch xác suất; sai số hiệu chỉnh kỳ vọng theo từng khoảng điểm.
Kiểm định DeLong	Kiểm định thống kê so sánh AUC của hai mô hình đánh giá trên cùng tập kiểm tra.
Pipeline	Chuỗi các bước xử lý nối tiếp từ dữ liệu thô đến kết quả dự báo.
FICO	Hệ thống chấm điểm tín dụng tuyến tính cổ điển, phổ biến tại Mỹ từ thập niên 1990.
Basel / GDPR	Hiệp ước an toàn vốn ngân hàng quốc tế / Quy định bảo vệ dữ liệu của EU — hai khung pháp lý yêu cầu mô hình tín dụng phải giải thích được.
LGD	Loss Given Default — tỷ lệ tổn thất thực tế trên dư nợ khi khoản vay vỡ nợ.

1 Giới thiệu

1.1 Tính cấp thiết

Tỷ lệ nợ xấu của hệ thống ngân hàng Việt Nam cuối năm 2023 ở mức 4,55% [1], phản ánh áp lực rủi ro tín dụng ngày càng lớn. Quy trình thẩm định thủ công không mở rộng được theo quy mô hồ sơ; trong khi các mô hình chấm điểm tuyến tính cổ điển bỏ qua các tương tác phi tuyến giữa thu nhập, dư nợ và lịch sử trễ hạn.

Học máy học quy luật rủi ro từ dữ liệu lịch sử quy mô lớn và nắm bắt được các tương tác phi tuyến này. Tuy nhiên, các mô hình mạnh thường mang tính “hộp đen”. Hiệp ước Basel và quy định bảo vệ dữ liệu (GDPR, Điều 22) yêu cầu tổ chức tín dụng phải *giải thích được* lý do từ chối một hồ sơ [2, 10]. Phương pháp SHAP [3] giải quyết yêu cầu này bằng cách quy mỗi quyết định về đóng góp của từng đặc trưng.

1.2 Mục tiêu (SMART)

Bảng 1.1: Mục tiêu cụ thể và kết quả đạt được của đồ án.

Mục tiêu	Chỉ tiêu	Kết quả
Xây dựng mô hình	$AUC \geq 0,87$	0,8714
So sánh 4 thuật toán	Bảng đầy đủ	Bảng 4.1
Thiết kế đặc trưng	≥ 2 đặc trưng mới vào top-5 SHAP	hạng 1 và 3
Tối ưu ngưỡng	Tối ưu theo F_2	$t = 0,625$, Recall 66,9%
Triển khai thử nghiệm	Ứng dụng web + giải thích SHAP	Đạt


1.3 Phạm vi

- **Dữ liệu:** *Give Me Some Credit* (Kaggle, 149.999 hồ sơ có nhãn trong `cs-training.csv`; `cs-test.csv` là tập nộp dự đoán, không có nhãn thật).
- **Mô hình:** bốn mô hình LR, DT, RF, XGBoost.
- **Không bao gồm:** mạng nơ-ron sâu, chấm điểm thời gian thực, tích hợp hệ thống.

- **Công nghệ:** Python 3.14, scikit-learn 1.8, XGBoost 3.2, SHAP 0.51.

1.4 Đóng góp chính và quy trình tổng quan

Đóng góp chính của đồ án gồm: (1) xây dựng đầy đủ quy trình từ khám phá dữ liệu đến demo sản phẩm; (2) thiết kế 4 đặc trưng mới có ý nghĩa nghiệp vụ, hai trong số đó giữ vị trí số 1 và số 3 theo SHAP; (3) chuẩn hóa cách chọn ngưỡng triển khai theo F_2 kèm hiệu chỉnh xác suất bằng Platt scaling; (4) đóng gói thành ứng dụng web hỗ trợ dự báo đơn lẻ và hậu kiểm theo lô. Toàn bộ quy trình được tóm tắt trong [Hình 1.1](#).



Hình 1.1: Sơ đồ quy trình tổng quan của đồ án.

2 Cơ sở lý thuyết

Chương này trình bày nền tảng toán học của các mô hình và độ đo được sử dụng, theo cách tiếp cận của các giáo trình kinh điển: *The Elements of Statistical Learning* của Hastie, Tibshirani và Friedman [12], *Pattern Recognition and Machine Learning* của Bishop [13], và *An Introduction to Statistical Learning* của James và cộng sự [14]. Mục tiêu là làm rõ vì sao mỗi mô hình hoạt động — và từ đó vì sao đồ án chọn dùng nó — thay vì chỉ mô tả cách dùng. Thứ tự trình bày đi theo độ phức tạp tăng dần: từ mô hình tuyến tính (Hồi quy Logistic), sang mô hình phi tuyến đơn (Cây quyết định), rồi đến hai họ mô hình tổ hợp (Rừng ngẫu nhiên — bagging, XGBoost — boosting); đây cũng chính là trật tự thực nghiệm ở [Chương 4](#).

2.1 Bài toán phân loại nhị phân

Định nghĩa 2.1 (Phân loại nhị phân). Cho không gian đặc trưng $\mathcal{X} \subseteq \mathbb{R}^p$ và nhãn $y \in \{0, 1\}$. Bài toán phân loại nhị phân là tìm hàm $f : \mathcal{X} \rightarrow [0, 1]$ ước lượng xác suất hậu nghiệm $f(\mathbf{x}) \approx \mathbb{P}(y = 1 \mid \mathbf{x})$. Quyết định cứng thu được qua một ngưỡng $t \in (0, 1)$:

$$\hat{y} = \mathbf{1}[f(\mathbf{x}) \geq t].$$

Trong bài toán của đồ án, $\mathbf{x}$ là véc-tơ thông tin một hồ sơ vay (tuổi, thu nhập, lịch sử trễ hạn...) và $y = 1$ nghĩa là hồ sơ đó vỡ nợ trong vòng 2 năm. Lưu ý cách đặt bài toán tách làm hai tầng: tầng *ước lượng xác suất* f (do mô hình học) và tầng *ra quyết định* qua ngưỡng t (do bài toán kinh doanh quyết định). Hai tầng này độc lập với nhau — cùng một mô hình f có thể vận hành với nhiều ngưỡng khác nhau tùy khẩu vị rủi ro. Đây là lý do báo cáo tách riêng việc huấn luyện mô hình ([Chương 4](#)) và việc chọn ngưỡng triển khai (tối ưu theo F_2), thay vì mặc nhiên dùng $t = 0,5$.

Mất cân bằng lớp. Trong bộ dữ liệu, tỷ lệ vỡ nợ chỉ 6,68%, tức tỷ lệ âm/dương xấp xỉ 14:1. Hệ quả là (i) độ chính xác tổng thể (accuracy) trở nên vô nghĩa — một bộ phân loại “lười” luôn dự báo “không vỡ nợ” đã đạt 93,32% accuracy mà không bắt được bất kỳ hồ sơ rủi ro nào; và (ii) ngưỡng tối ưu thường khác xa 0,5, vì hàm mất mát chuẩn bị lớp đa số lần ít. Theo khuyến nghị chung cho dữ liệu mất cân bằng [22, 14], ta đánh giá bằng AUC, F_β và chi phí kỳ vọng thay vì accuracy (xem [Mục 2.6](#)), đồng thời can thiệp vào hàm mất mát bằng trọng số lớp (xem [Mục 3.5](#)).

2.2 Hồi quy Logistic

Hồi quy Logistic [12, Ch. 4.4] là mô hình tuyến tính chuẩn mực cho phân loại nhị phân và là điểm xuất phát truyền thống của chấm điểm tín dụng (các hệ thống kiểu FICO về bản chất là mô hình chấm điểm tuyến tính). Đồ án dùng nó làm *mô hình mốc* (baseline): mọi mô hình phức tạp hơn phải thắng nó một khoảng đủ lớn thì độ phức tạp thêm mới đáng giá. Mô hình hóa xác suất hậu nghiệm bằng hàm sigmoid $\sigma(z) = \frac{1}{1 + e^{-z}}$ áp lên một tổ hợp tuyến tính của đặc trưng:

$$p_i := \mathbb{P}(y_i = 1 \mid \mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b) = \frac{1}{1 + \exp(-(\mathbf{w}^\top \mathbf{x}_i + b))}. \quad (2.1)$$

Tham số $(\mathbf{w}, b)$ được ước lượng theo nguyên lý hợp lý cực đại (MLE). Với giả thiết các quan sát độc lập tuân theo phân phối Bernoulli, hàm hợp lý là $\prod_i p_i^{y_i} (1 - p_i)^{1-y_i}$. Lấy logarit âm và chia cho N ta được hàm mất mát *cross-entropy* (log-loss):

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]. \quad (2.2)$$

Mệnh đề 2.2 (Gradient và tính lồi). Đặt $X \in \mathbb{R}^{N \times p}$ là ma trận đặc trưng, $\mathbf{p} = (p_i)$, $\mathbf{y} = (y_i)$. Khi đó

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{N} X^\top (\mathbf{p} - \mathbf{y}), \quad \nabla_{\mathbf{w}}^2 \mathcal{L} = \frac{1}{N} X^\top S X,$$

với $S = \text{diag}(p_i(1 - p_i)) \succeq 0$. Do đó $\mathcal{L}$ là hàm lồi theo $\mathbf{w}$, và mọi điểm dừng đều là cực tiểu toàn cục.

Chứng minh. Dùng $\sigma'(z) = \sigma(z)(1 - \sigma(z))$. Với một quan sát, $\partial \mathcal{L}_i / \partial \mathbf{w} = -(y_i - p_i) \mathbf{x}_i = (p_i - y_i) \mathbf{x}_i$; lấy trung bình cho công thức gradient. Đạo hàm thêm một lần: $\partial p_i / \partial \mathbf{w} = p_i(1 - p_i) \mathbf{x}_i$, suy ra Hessian $= \frac{1}{N} \sum_i p_i(1 - p_i) \mathbf{x}_i \mathbf{x}_i^\top = \frac{1}{N} X^\top S X$. Với mọi $\mathbf{v}$, $\mathbf{v}^\top X^\top S X \mathbf{v} = \sum_i p_i(1 - p_i) (\mathbf{x}_i^\top \mathbf{v})^2 \geq 0$ vì $p_i \in (0, 1)$. Vậy Hessian nửa xác định dương, $\mathcal{L}$ lồi. ■

Biến đổi **công thức (2.1)** cho thấy ý nghĩa diễn giải của mô hình: logarit của tỷ số khả năng (log-odds) là hàm *tuyến tính* theo đặc trưng,

$$\log \frac{p_i}{1 - p_i} = \mathbf{w}^\top \mathbf{x}_i + b,$$

nên mỗi hệ số w_j đọc được trực tiếp: tăng đặc trưng j thêm một đơn vị (giữ nguyên các đặc trưng khác) làm log-odds vỡ nợ tăng đúng w_j . Tính chất này khiến Hồi quy Logistic được ưa chuộng trong môi trường có ràng buộc pháp lý về giải thích quyết định.

Vì sao chọn / hạn chế. Nhanh, ổn định, hệ số diễn giải trực tiếp — là mốc so sánh bắt buộc. Hạn chế cốt lõi: biên quyết định tuyến tính, nên không tự biểu diễn được các tương tác kiểu “thu nhập thấp và đồng thời dùng kiệt hạn mức” — đúng loại quan hệ mà dữ liệu tín dụng chứa nhiều. Khắc phục đòi hỏi tự tay tạo biến tương tác (xem thiết kế đặc trưng, [Chương 3](#)) hoặc

chuyển sang mô hình phi tuyến.

2.3 Cây quyết định (CART)

Cây quyết định, theo thuật toán CART của Breiman và cộng sự [15] (trình bày hiện đại trong [12, Ch. 9.2]), phân hoạch đệ quy không gian đặc trưng thành các vùng hình hộp, mỗi vùng gán một dự báo. Cách phân hoạch này mô phỏng đúng lối tư duy của cán bộ thẩm định: “nếu từng trễ hạn trên 90 ngày và tỷ lệ dùng hạn mức trên 80% thì rủi ro cao” — vì vậy đây là mô hình phi tuyến tự nhiên đầu tiên để thử trong bài toán tín dụng.

Tại mỗi nút, CART chọn cặp (đặc trưng, ngưỡng) làm giảm *độ pha tạp* (impurity — mức độ lẫn lộn giữa các lớp trong nút) nhiều nhất. Với một nút t chứa tỉ lệ lớp $p_{k|t}$, hai độ đo pha tạp thông dụng là

$$\underbrace{G(t) = 1 - \sum_k p_{k|t}^2}_{\text{Gini}}, \quad \underbrace{H(t) = - \sum_k p_{k|t} \log_2 p_{k|t}}_{\text{Entropy}}. \quad (2.3)$$

Chỉ số Gini $G(t)$ có diễn giải xác suất gọn: đó là xác suất phân loại sai nếu gán nhãn một mẫu ngẫu nhiên trong nút theo đúng phân phối lớp của nút; entropy $H(t)$ đo lượng thông tin (bit) còn thiếu để biết chắc nhãn. Cả hai đạt 0 khi nút thuần một lớp và đạt cực đại khi các lớp đều nhau — thực nghiệm cho thấy hai tiêu chí cho cây gần như tương đương [12, Ch. 9.2.3]; đồ án dùng Gini theo mặc định của scikit-learn. Một phép chia s tách nút cha thành nút con trái/phải với số mẫu N_L, N_R ($N = N_L + N_R$). Độ giảm pha tạp (information gain — độ lợi thông tin) là

$$\Delta I(s, t) = I(t) - \frac{N_L}{N} I(t_L) - \frac{N_R}{N} I(t_R), \quad (2.4)$$

và CART chọn $s^* = \arg \max_s \Delta I(s, t)$. Cây dừng khi đạt độ sâu tối đa hoặc số mẫu lá tối thiểu. **Vì sao chọn / hạn chế.** Trực quan, mô tả được logic quyết định bằng các luật nếu—thì, bắt được quan hệ phi tuyến mà không cần chuẩn hóa dữ liệu. Nhưng một cây đơn dễ *quá khớp* (overfitting — học thuộc cả nhiễu của tập huấn luyện) và có phương sai cao: thay đổi nhỏ trong dữ liệu có thể cho ra cây hoàn toàn khác [12, Ch. 8.7]. Chính nhược điểm này là động lực cho các mô hình tổ hợp ở hai mục tiếp theo.

2.4 Bagging và Rừng ngẫu nhiên

Bagging (bootstrap aggregating [16]) giảm phương sai của một mô hình không ổn định bằng cách huấn luyện B bản sao trên các mẫu bootstrap (lấy mẫu lại có hoàn lại) khác nhau rồi lấy trung bình dự báo. Rừng ngẫu nhiên [7] áp dụng ý tưởng này cho cây quyết định. Cơ chế giảm phương sai được làm rõ bởi kết quả sau, trình bày theo [12, Ch. 15.2].

Mệnh đề 2.3 (Giảm phương sai nhờ trung bình hóa). *Giả sử B cây cho dự báo $\{Z_b\}$ cùng phân*

phối, mỗi cái có phương sai σ^2 và tương quan từng cặp $\rho \geq 0$. Khi đó phương sai của dự báo trung bình $\bar{Z} = \frac{1}{B} \sum_b Z_b$ là

$$\text{Var}(\bar{Z}) = \rho \sigma^2 + \frac{1-\rho}{B} \sigma^2 \xrightarrow{B \rightarrow \infty} \rho \sigma^2. \quad (2.5)$$

Chứng minh. $\text{Var}(\bar{Z}) = \frac{1}{B^2} [\sum_b \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'})] = \frac{1}{B^2} [B\sigma^2 + B(B-1)\rho\sigma^2] = \frac{\sigma^2}{B} + \frac{B-1}{B} \rho\sigma^2$, rút gọn ra **công thức (2.5)**. ■

Số hạng thứ hai $\frac{1-\rho}{B} \sigma^2$ triệt tiêu khi tăng B , nhưng số hạng $\rho\sigma^2$ thì không: trung bình hóa nhiều cây *giống nhau* không giúp được gì. Vì thế Rừng ngẫu nhiên còn *lấy ngẫu nhiên một tập con đặc trưng* tại mỗi phép chia để *giảm tương quan* ρ giữa các cây — đó là điểm khác biệt cốt lõi so với bagging thuần và là lý do nó thường thắng bagging trong thực tế [12, Ch. 15].

Vì sao chọn / hạn chế. Ổn định hơn hẳn cây đơn, kháng nhiễu tốt, ít phải tinh chỉnh; là đại diện tiêu biểu của hướng *giảm phương sai*. Đổi lại, hàng trăm cây cộng gộp không còn đọc trực tiếp được như một cây — phân diễn giải phải nhờ đến công cụ hậu nghiệm như SHAP (Mục 2.7).

2.5 Gradient Boosting và XGBoost

Boosting đi theo hướng ngược với bagging: thay vì giảm phương sai của các mô hình mạnh huấn luyện song song, nó *giảm độ chệch* bằng cách cộng dồn tuần tự các mô hình yếu — cây thứ t tập trung sửa phần sai số còn lại của tổ hợp $t-1$ cây trước. Friedman đặt nền tảng cho cách nhìn này dưới dạng *hạ gradient trong không gian hàm* (gradient boosting) [17]; XGBoost [4] là hiện thực hiện đại với hai cải tiến chính: thêm chính quy hóa tường minh vào hàm mục tiêu và dùng xấp xỉ Newton bậc hai. Dự báo sau t vòng là $\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)$, với f_t là một cây hồi quy. XGBoost cực tiểu hàm mục tiêu *có chính quy hóa*:

$$\mathcal{L}^{(t)} = \sum_{i=1}^N l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2, \quad (2.6)$$

trong đó T là số lá, $\mathbf{w}$ là véc-tơ trọng số lá, $\gamma, \lambda \geq 0$ kiểm soát độ phức tạp. Khai triển Taylor bậc hai quanh $\hat{y}^{(t-1)}$ với $g_i = \partial_{\hat{y}} l$, $h_i = \partial_{\hat{y}}^2 l$:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^N \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2 \right] + \Omega(f_t) + \text{const}. \quad (2.7)$$

Định lý 2.4 (Trọng số lá tối ưu và độ lợi phép chia). Với một cấu trúc cây cố định, gọi I_j là tập mẫu rơi vào lá j , và đặt $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$. Khi đó trọng số lá tối ưu và

giá trị mục tiêu tối ưu tương ứng là

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \tilde{\mathcal{L}}^{(t)} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T. \quad (2.8)$$

Độ lợi (gain) khi tách một lá thành hai lá trái/phải là

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma. \quad (2.9)$$

Chứng minh. Vì một cây gán cùng một trọng số w_j cho mọi mẫu trong lá j , nhóm tổng theo lá: $\mathcal{L}^{(t)} = \sum_{j=1}^T [G_j w_j + \frac{1}{2}(H_j + \lambda)w_j^2] + \gamma T$. Đây là tam thức bậc hai theo w_j với hệ số bậc hai dương; cực tiểu đạt tại $w_j^* = -G_j/(H_j + \lambda)$. Thế lại được $\tilde{\mathcal{L}}^{(t)} = -\frac{1}{2} \sum_j G_j^2/(H_j + \lambda) + \gamma T$. Độ lợi của phép chia là chênh lệch giá trị mục tiêu trước và sau khi tách, cho ra [công thức \(2.9\)](#). ■

Công thức [công thức \(2.9\)](#) chính là tiêu chí XGBoost dùng để chọn điểm chia: nó thường cho phép chia làm giảm mục tiêu và phạt γ cho mỗi lá mới, tạo cơ chế cắt tia tự nhiên. Việc dùng cả g_i và h_i (Newton bậc hai) khiến XGBoost hội tụ nhanh và ổn định hơn boosting bậc nhất.

Vì sao chọn / hạn chế. Họ gradient boosting trên cây hiện là chuẩn mực thực tế cho dữ liệu dạng bảng — như bài toán hồ sơ tín dụng của đồ án — nhờ kết hợp được sức mạnh phi tuyến của cây với cơ chế kiểm soát quá khớp tường minh (γ , λ , learning rate, lấy mẫu con). Riêng với mất cân bằng lớp, tham số `scale_pos_weight` nhân trọng số của các mẫu dương trong g_i, h_i , tức can thiệp *ngay trong hàm mất mát* thay vì phải biến đổi dữ liệu. Hạn chế: nhiều siêu tham số cần tinh chỉnh và, như mọi mô hình tổ hợp, cần SHAP để diễn giải.

2.6 Độ đo đánh giá

Từ ma trận nhầm lẫn (TP, FP, FN, TN) định nghĩa Precision = $\frac{TP}{TP+FP}$ (trong số hồ sơ bị từ chối, bao nhiêu thật sự sẽ vỡ nợ) và Recall = $\frac{TP}{TP+FN}$ (trong số hồ sơ sẽ vỡ nợ, mô hình bắt được bao nhiêu). Hai đại lượng này đối kháng nhau qua ngưỡng: hạ ngưỡng thì Recall tăng nhưng Precision giảm. Tổng quát hóa qua trung bình điều hòa có trọng số là F_β [\[24\]](#):

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}}. \quad (2.10)$$

Tham số β đặt tầm quan trọng của Recall gấp β lần Precision; ta chọn $\beta = 2$ vì trong tín dụng, bỏ sót người vỡ nợ (FN) tốn kém hơn từ chối nhầm (FP).

Định lý 2.5 (Diễn giải xác suất của AUC). Gọi $\mathbf{x}^+$ là một mẫu dương và $\mathbf{x}^-$ là một mẫu âm lấy ngẫu nhiên độc lập. Khi đó diện tích dưới đường cong ROC bằng xác suất mô hình xếp mẫu dương cao hơn mẫu âm:

$$\text{AUC} = \mathbb{P}(f(\mathbf{x}^+) > f(\mathbf{x}^-)) + \frac{1}{2}\mathbb{P}(f(\mathbf{x}^+) = f(\mathbf{x}^-)). \quad (2.11)$$

Phác thảo. Đường ROC là đồ thị $\text{TPR}(t)$ theo $\text{FPR}(t)$ khi quét ngưỡng t . Đổi biến, $\text{AUC} = \int_0^1 \text{TPR} d(\text{FPR}) = \int \mathbb{P}(f(\mathbf{x}^+) > t) d\mathbb{P}(f(\mathbf{x}^-) \leq t)$, chính là $\mathbb{P}(f(\mathbf{x}^+) > f(\mathbf{x}^-))$ (cộng nửa khối lượng tại các điểm bằng nhau). Đây cũng là thống kê U Mann–Whitney chuẩn hóa, nên AUC bất biến với mọi phép biến đổi đơn điệu của điểm số. ■

Nhận xét 2.6 (Ngưỡng Bayes tối ưu theo chi phí). Nếu chi phí của một FP là c_{FP} và của một FN là c_{FN} , quy tắc cực tiểu chi phí kỳ vọng là dự báo dương khi $p > t^*$ với $t^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$ [20]. Chi phí FN càng lớn thì ngưỡng càng thấp.

Kết quả này đẹp về lý thuyết nhưng giả định mô hình cho xác suất *đúng tuyệt đối* và chi phí *cố định cho mọi hồ sơ* — hai giả định đều không chắc trong thực tế. Đây là lý do ở [Chương 4](#) đề án dùng nó làm điểm tham chiếu nhưng chọn ngưỡng triển khai bằng cách tối ưu trực tiếp F_2 trên tập kiểm định.

2.7 Diễn giải mô hình bằng SHAP

SHAP (SHapley Additive exPlanations) [3] gán cho mỗi đặc trưng i một đóng góp ϕ_i vào chênh lệch giữa dự báo của một hồ sơ cụ thể và giá trị nền (dự báo trung bình), dựa trên *giá trị Shapley* từ lý thuyết trò chơi hợp tác [18]: xem mỗi đặc trưng như một “người chơi” và dự báo như “phần thưởng” cần chia công bằng. Với hàm giá trị $v(S)$ là dự báo kỳ vọng khi chỉ biết tập đặc trưng S :

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [v(S \cup \{i\}) - v(S)]. \quad (2.12)$$

Giá trị Shapley là cách phân bổ *duy nhất* thỏa đồng thời bốn tiên đề: tính hiệu quả ($\sum_i \phi_i$ bằng chênh lệch dự báo), đối xứng, đặc trưng vô dụng có $\phi_i = 0$, và tính cộng tính [18, 11]. Tính duy nhất này là lý do đề án chọn SHAP thay vì các phương pháp diễn giải khác (như độ quan trọng theo permutation hay LIME): lời giải thích có cơ sở tiên đề rõ ràng, cộng đúng bằng dự báo, áp dụng được cho *từng hồ sơ* — khớp yêu cầu pháp lý phải nêu lý do khi từ chối một khách hàng cụ thể. Với mô hình cây, TreeExplainer [19] tính [công thức \(2.12\)](#) chính xác theo thời gian đa thức, tránh chi phí tổ hợp $2^{|F|}$ — nhờ đó dùng được trong ứng dụng tương tác.

2.8 Hiệu chỉnh xác suất và kiểm định thống kê

Một mô hình xếp hạng tốt (AUC cao) chưa chắc cho *xác suất* đúng nghĩa: các mô hình boosting có xu hướng đẩy điểm số dồn về hai phía, lệch khỏi tần suất thực tế [23]. Trong tín dụng điều này quan trọng vì xác suất vỡ nợ còn được dùng để định giá lãi suất và trích lập dự phòng, không chỉ để xếp hạng. *Platt scaling* [9] hiệu chỉnh bằng một hồi quy logistic một biến trên điểm số: $\hat{p} = \sigma(a f(\mathbf{x}) + b)$; chỉ có 2 tham số (a, b) nên ít rủi ro quá khớp trên tập kiểm định cỡ vừa — lý do đồ án chọn nó thay vì hồi quy isotonic (phi tham số, cần nhiều dữ liệu dương hơn). Chất lượng hiệu chỉnh đo bằng điểm Brier $BS = \frac{1}{N} \sum_i (\hat{p}_i - y_i)^2$ và sai số hiệu chỉnh kỳ vọng ECE (chênh lệch trung bình giữa xác suất dự báo và tần suất thật theo từng khoảng điểm). Cuối cùng, để kiểm tra chênh lệch AUC giữa hai mô hình đánh giá trên *cùng* tập kiểm tra (do đó tương quan với nhau) có ý nghĩa thống kê hay không, ta dùng kiểm định DeLong [8].

3 Dữ liệu và Tiền xử lý

3.1 Khám phá dữ liệu (EDA)


Bộ dữ liệu gồm 149.999 hồ sơ (sau khi loại 1 dòng có tuổi = 0 — giá trị không hợp lệ về nghiệp vụ), 10 đặc trưng gốc gồm 3 nhóm: thông tin nhân khẩu (tuổi, số người phụ thuộc), năng lực tài chính (thu nhập tháng, tỷ lệ nợ, tỷ lệ dùng hạn mức tín dụng quay vòng) và lịch sử trễ hạn (số lần trễ 30–59, 60–89 và trên 90 ngày). Nhãn `SeriousDlqin2yrs` bằng 1 nếu hồ sơ trễ hạn nghiêm trọng trong vòng 2 năm sau đó. [Bảng 3.1](#) mô tả đầy đủ từng biến.

Bảng 3.1: Các biến gốc của bộ dữ liệu *Give Me Some Credit*.

Biến	Ý nghĩa	Thiếu
<code>SeriousDlqin2yrs</code> (nhãn)	Trễ hạn ≥ 90 ngày trong 2 năm tới (0/1)	0%
<code>RevolvingUtilization...</code>	Dư nợ thẻ/hạn mức quay vòng so với tổng hạn mức (tỷ lệ)	0%
<code>age</code>	Tuổi người vay (năm)	0%
<code>NumberOfTime30-59Days...</code>	Số lần trễ hạn 30–59 ngày trong 2 năm qua	0%
<code>DebtRatio</code>	(Trả nợ tháng + chi phí sinh hoạt) / thu nhập gộp tháng	0%
<code>MonthlyIncome</code>	Thu nhập tháng (USD)	19,8%
<code>NumberOfOpenCreditLines...</code>	Số dòng tín dụng và khoản vay đang mở	0%
<code>NumberOfTimes90DaysLate</code>	Số lần trễ hạn ≥ 90 ngày	0%
<code>NumberRealEstateLoans...</code>	Số khoản vay/bảo đảm bất động sản	0%
<code>NumberOfTime60-89Days...</code>	Số lần trễ hạn 60–89 ngày	0%
<code>NumberOfDependents</code>	Số người phụ thuộc trong gia đình	2,6%

[Hình 3.1](#) cho thấy đặc điểm chi phối toàn bộ thiết kế phía sau: chỉ 9.951 hồ sơ vỡ nợ so với 140.048 hồ sơ tốt (6,68%, tỷ lệ $\approx 14:1$). Cột bên trái áp đảo hoàn toàn — mọi lựa chọn về độ đo, hàm mất mát và ngưỡng quyết định ở các chương sau đều phải tính đến sự lệch này.

[Hình 3.2](#) trình bày phân phối từng đặc trưng gốc. Hai điểm đáng chú ý: (i) `RevolvingUtilization` và `DebtRatio` lệch phải rất nặng, có những giá trị lớn bất thường (tỷ lệ dùng hạn mức hàng nghìn lần — nhiều khả năng là lỗi nhập liệu hoặc đơn vị); (ii) tuổi phân bố tương đối chuẩn quanh 45–50, còn các biến đếm lần trễ hạn tập trung gần như toàn bộ ở 0. Về xử lý, đồ án *giữ nguyên* các giá trị cực trị thay vì cắt bỏ: chúng có thể chính là tín hiệu rủi ro thật, và hai lớp phòng vệ đã có sẵn trong thiết kế — mô hình cây chia nút theo *thứ tự* giá trị nên miễn nhiễm với độ lớn tuyệt đối của cực trị, còn Hồi quy Logistic được bảo vệ bằng phép chuẩn hóa bền vững `RobustScaler` (xem [Mục 3.3](#)).



Hình 3.1: Phân bố lớp mục tiêu — mất cân bằng $\approx 14:1$.

Hình 3.3 là ma trận tương quan *hạng Spearman* giữa các đặc trưng (gồm cả bốn đặc trưng thiết kế ở **Mục 3.4**, đưa vào đây để tiện đối chiếu). Chọn Spearman thay vì Pearson vì nó dựa trên thứ hạng nên không bị các giá trị cực trị nêu trên kéo lệch. Ba điểm đọc được từ hình: (i) các biến gốc phần lớn tương quan yếu với nhau ($|\rho| < 0,3$) — mỗi biến mang thông tin tương đối độc lập; (ii) các đặc trưng tổng hợp tương quan mạnh với đúng các biến thành phần của chúng (Điểm trễ hạn với Trễ 30–59 ngày: 0,82; Áp lực tài chính với Điểm trễ hạn: 0,96) — đúng như cách xây dựng; (iii) hàng nhân SeriousDlqin2yrs cho thấy nhóm trễ hạn và các đặc trưng tổng hợp có liên hệ hạng cao nhất với vỡ nợ, trong khi thu nhập, tỷ lệ nợ gần như không có tương quan hạng đơn biến — gợi ý vai trò của chúng nằm ở *tương tác* với biến khác chứ không ở tác động trực tiếp.


Hình 3.4 đào sâu nhóm biến trễ hạn theo nhân: so với mức nền 6,7%, hồ sơ chưa từng trễ hạn 90+ ngày chỉ vỡ nợ khoảng 5%, nhưng *một* lần trễ 90+ ngày đã đẩy tỷ lệ lên trên 30%, và tái diễn nhiều lần đẩy lên 50–60%. Độ dốc này tăng theo mức độ nặng của trễ hạn (cùng một lần trễ, mức 30–59 ngày chỉ nâng tỷ lệ lên $\sim 15\%$). Đây là tín hiệu dự báo mạnh nhất trong dữ liệu, và là cơ sở thực nghiệm cho cách đánh trọng số 3:2:1 trong đặc trưng TotalDelinquencyScore ở **Mục 3.4**: mức trễ hạn càng nặng, liên hệ với vỡ nợ càng dốc.

3.2 Xử lý giá trị thiếu


Hai biến có khuyết thiếu đáng kể: MonthlyIncome (19,8%) và số người phụ thuộc (2,6%). Khuyết thiếu của thu nhập nhiều khả năng *không ngẫu nhiên hoàn toàn*: người không khai thu nhập có thể khác hệ thống với người khai (ví dụ lao động tự do), nên loại bỏ 19,8% số dòng vừa lãng phí dữ liệu vừa có nguy cơ làm lệch mẫu.

Giữa các phương án điền khuyết, đề án cân nhắc cụ thể như sau:


- *Điền trung bình/trung vị*: đơn giản nhưng gán *cùng một giá trị* cho mọi hồ sơ thiếu, làm phân phối dồn cục tại một điểm và phá vỡ tương quan giữa thu nhập với các biến khác



Hình 3.2: Phân phối đơn biến của các đặc trưng gốc.



Hình 3.3: Ma trận tương quan giữa các đặc trưng.




Hình 3.4: Phân tích nhóm biến trễ hạn theo tỷ lệ vỡ nợ.

(một người 25 tuổi ít hạn mức và một người 50 tuổi nhiều hạn mức đều bị gán cùng mức thu nhập).

- *KNN Imputer* ($k = 5$, được chọn): điền bằng trung bình của 5 hồ sơ giống nhất theo khoảng cách Euclid trên các chiều quan sát được — hồ sơ thiếu thu nhập được ước lượng từ những hồ sơ *có cùng hồ sơ tín dụng*, nên giữ được cấu trúc tương quan. Chọn $k = 5$ làm điểm cân bằng: k quá nhỏ thì nhạy nhiễu, k quá lớn thì tiến dần về điền trung bình toàn cục.

Hình 3.5 cung cấp hai bằng chứng cho các nhận định trên. Panel trái cho thấy hậu quả của điền trung vị: toàn bộ 19,8% hồ sơ thiếu bị dồn vào một đỉnh nhọn nhân tạo tại 5.400 USD, phá vỡ hình dạng phân phối quan sát được (đường xanh). Panel phải so sánh tỷ lệ vỡ nợ giữa nhóm có và thiếu thu nhập (6,9% so với 5,6%): hai nhóm khác nhau thật sự về rủi ro, xác nhận khuyết thiếu *mang thông tin* — vì vậy không thể xóa dòng, và giá trị điền nên phụ thuộc vào hồ sơ cụ thể (KNN) thay vì một hằng số chung. Bộ điền khuyết được khớp (fit) *chỉ trên tập huấn luyện* rồi áp sang tập kiểm định/kiểm tra, tránh rò rỉ thông tin từ dữ liệu đánh giá.



Hình 3.5: Trái: điền trung vị tạo đỉnh nhọn nhân tạo tại 5.400 USD. Phải: tỷ lệ vỡ nợ theo trạng thái thiếu thu nhập — khuyết thiếu mang thông tin.

3.3 Chuẩn hóa

Áp dụng *RobustScaler* *chỉ cho Hồi quy Logistic*. Lý do cần chuẩn hóa: thuật toán tối ưu hội tụ ổn định hơn khi các đặc trưng cùng thang đo (thu nhập cỡ hàng nghìn USD đứng cạnh tỷ lệ cơ [0, 1] làm mặt mát mát rất dẹt theo một chiều), và hệ số sau chuẩn hóa so sánh được với nhau về độ lớn. Lý do chọn bản *robust* (trừ trung vị, chia khoảng tứ phân vị) thay vì chuẩn hóa thông thường theo trung bình/độ lệch chuẩn: như đã thấy ở **Hình 3.2**, nhiều biến chứa cực trị rất lớn — chỉ một giá trị *DebtRatio* hàng chục nghìn đã đủ thổi phồng độ lệch chuẩn và nén toàn bộ phần còn lại của thang đo về gần 0; trung vị và IQR thì miễn nhiễm. Các mô hình cây (DT, RF, XGBoost) chia nút theo *thứ tự* giá trị nên bất biến với mọi phép biến đổi đơn điệu — chuẩn hóa không thay đổi kết quả, do đó không áp dụng để giữ nguyên thang đo gốc để diễn giải. Tương

tự bộ điền khuyết, scaler chỉ được khớp trên tập huấn luyện (nằm trong cùng một pipeline với mô hình).

3.4 Thiết kế đặc trưng

Mô hình cây tự bắt được tương tác, nhưng chỉ qua nhiều phép chia liên tiếp trên dữ liệu đủ dày — với lớp dương chỉ có ~ 10 nghìn mẫu, việc “gói sẵn” tri thức nghiệp vụ vào một biến đơn giúp mô hình học nhanh hơn và lời giải thích SHAP gọn hơn. Mỗi đặc trưng dưới đây vì vậy được thiết kế với ý đồ *kép*: một lý do nghiệp vụ (tín hiệu rủi ro nào) và một lý do học máy (giúp mô hình ở điểm nào).

1. $\text{TotalDelinquencyScore} = 3 \times (90+) + 2 \times (60-89) + 1 \times (30-59)$.

Nghệp vụ: mức độ trễ hạn càng nặng càng báo hiệu mất khả năng trả nợ; trọng số 3:2:1 phạt lũy tiến theo độ nặng, nhất quán với độ dốc quan sát được ở [Hình 3.4](#).

Học máy: ba biến đếm gốc rất thừa (đại đa số hồ sơ bằng 0, [Hình 3.2](#)) nên từng biến riêng lẻ mang ít thông tin cho một phép chia; gộp có trọng số thành một trục “cường độ trễ hạn” liên tục cô đọng tín hiệu vào một biến duy nhất — đặc biệt có giá trị cho Hồi quy Logistic, vốn không tự tổ hợp được các biến theo bậc thang độ nặng.

2. $\text{FinancialStressIndex} = \text{RevolvingUtil} \times \text{TotalDelinquencyScore}$.

Nghệp vụ: dùng kiệt hạn mức và *đồng thời* đang trễ hạn là cặp tín hiệu của người vay xoay vòng nợ để sống — nguy hiểm hơn nhiều so với từng tín hiệu riêng lẻ.

Học máy: đây là một *biến tương tác* tường minh. Hồi quy Logistic hoàn toàn không biểu diễn được tích hai biến; cây thì cần nhiều tầng chia mới xấp xỉ được. Cấp sẵn tích này cho mọi mô hình cùng hưởng lợi.

3. $\text{AbsoluteMonthlyDebt} = \text{DebtRatio} \times \text{MonthlyIncome}$.

Nghệp vụ: cùng tỷ lệ nợ 50% nhưng nghĩa hoàn toàn khác giữa người thu nhập 2 nghìn và 20 nghìn USD/tháng; quy về số tiền nợ tuyệt đối bổ sung chiều thông tin mà tỷ lệ che mất.

Học máy: tách cặp biến tỷ lệ–quy mô thành một biến mức (level) trực giao hơn với hai biến gốc, giảm gánh nặng học tương tác chia/nhân cho mô hình.

4. $\text{DelinquencySeverityBalance} = (30-59) - (90+)$ (tên trong mã nguồn: `DelinquencyTrend`).

Nghệp vụ: dữ liệu là ảnh chụp tĩnh một thời điểm, không có chuỗi thời gian; hiệu số này xấp xỉ “pha” của vòng xoay nợ — dương nghĩa là trễ hạn chủ yếu còn ở mức nhẹ (mới bắt đầu khó khăn), âm nghĩa là đã dồn về mức nặng.

Học máy: cung cấp thông tin *tương phản* giữa hai đầu thang trễ hạn, điều mà tổng có trọng số (đặc trưng 1) đã làm mờ đi; hai biến bổ sung nhau thay vì trùng lặp.

Hiệu quả của thiết kế này được kiểm chứng định lượng ở [Mục 4.3](#): hai trong bốn đặc trưng trên vào top-3 độ quan trọng SHAP, đứng trên hầu hết biến gốc.

3.5 Mất cân bằng lớp

Có ba hướng xử lý mất cân bằng 14:1 [22]: (a) lấy mẫu lại dữ liệu — giảm lớp đa số (undersampling) hoặc sinh thêm lớp thiểu số tổng hợp (SMOTE [21]); (b) đánh lại trọng số lớp trong hàm mất mát; (c) giữ nguyên mô hình, xử lý ở khâu chọn ngưỡng. Đồ án khảo sát cả ba và quyết định kết hợp (b) với (c), với lý do cụ thể từng phương án:

- *Loại undersampling*: vứt bỏ tới ~ 130 nghìn hồ sơ tốt — mất thông tin không cần thiết khi dữ liệu không hề thừa.
- *Loại SMOTE*: mẫu tổng hợp được nội suy tuyến tính giữa các mẫu thật, nhưng các biến tài chính ở đây lệch nặng và chứa cực trị (Hình 3.2), nên điểm nội suy có thể là hồ sơ “không tồn tại được” về nghiệp vụ; SMOTE cũng làm méo phân phối lớp khiến xác suất đầu ra mất hiệu chỉnh, và nếu áp dụng trước khi chia kiểm định chéo sẽ rò rỉ thông tin (bản sao tổng hợp của một mẫu xuất hiện ở cả phần huấn luyện lẫn phần đánh giá). Minh họa cơ chế SMOTE được chuyển vào Phụ lục B để tham khảo.
- *Chọn trọng số lớp*: đặt $\text{scale_pos_weight} = n_-/n_+ \approx 14$ trong XGBoost (và class_weight tương ứng ở các mô hình sklearn) — mỗi mẫu vỡ nợ đóng góp vào gradient của hàm mất mát gấp ~ 14 lần mẫu thường, mô hình buộc phải “để ý” lớp thiểu số mà không bịa thêm dữ liệu, không đổi phân phối gốc, tương thích trơn tru với kiểm định chéo.
- *Kết hợp chọn ngưỡng*: phần thiên lệch còn lại được xử lý nốt ở tầng quyết định bằng cách tối ưu ngưỡng theo F_2 (Chương 4), đúng tinh thần tách hai tầng ước lượng/quyết định đã nêu ở Chương 2.

4 Thực nghiệm và Đánh giá

4.1 Thiết kế thử nghiệm

Chia dữ liệu theo tỷ lệ 70/15/15: huấn luyện 104.999, kiểm định 22.500, kiểm tra 22.500 hồ sơ. Cần *ba* phần thay vì hai vì đề án có hai việc dùng dữ liệu ngoài huấn luyện: chọn siêu tham số và ngưỡng quyết định (trên tập kiểm định) và báo cáo kết quả cuối cùng (trên tập kiểm tra). Nếu chọn ngưỡng và báo cáo trên cùng một tập, con số cuối sẽ lạc quan hơn thực tế vì ngưỡng đã “nhìn thấy” tập đó. Cả ba phần đều chia *phân tầng* (stratified — giữ nguyên tỷ lệ vỡ nợ 6,68% trong từng phần): với lớp dương hiếm, chia ngẫu nhiên thuần có thể làm lệch tỷ lệ giữa các phần và khiến so sánh thiếu công bằng. Siêu tham số được tìm bằng RandomizedSearchCV (lấy mẫu ngẫu nhiên 15–20 cấu hình từ lưới tham số của từng mô hình — hiệu quả hơn duyệt toàn bộ lưới khi không gian tìm kiếm lớn), chấm điểm bằng AUC qua kiểm định chéo phân tầng $k = 5$ trên tập huấn luyện; chọn $k = 5$ là điểm cân bằng thông dụng giữa độ ổn định của ước lượng và chi phí tính toán [14, Ch. 5]. Cả bốn mô hình đều được bù mất cân bằng ngay trong hàm mất mát: `class_weight=balanced` với LR/DT/RF và `scale_pos_weight  $\approx 14$` với XGBoost. Bốn mô hình được so sánh đúng theo trật tự lý thuyết ở [Chương 2](#): mốc tuyến tính $\rightarrow$ phi tuyến đơn $\rightarrow$ tổ hợp giảm phương sai $\rightarrow$ tổ hợp giảm độ chệch.

Về tính tái lập: mọi con số trong chương này được tính từ đúng bốn mô hình đã lưu trong `models/` áp lên các tập chia cố định trong `data/splits/`; hai script `final_report/verify_numbers.py` và `final_report/regen_figs.py` cho phép tái tạo toàn bộ bảng số và hình vẽ.

4.2 So sánh mô hình

Kết quả tổng hợp cho trong [Bảng 4.1](#). Hai quan sát đáng chú ý. *Thứ nhất*, mô hình tổ hợp đứng đầu đúng như lý thuyết: XGBoost (0,8714) và RF (0,8671) vượt hai mô hình đơn, phản ánh hiệu quả của giảm phương sai (RF) và giảm độ chệch tuần tự (XGBoost). *Thứ hai* — và thú vị hơn — Hồi quy Logistic (0,8630) vượt cây đơn (0,8579), trái với trực giác “phi tuyến thì hơn tuyến tính”. Điều này lý giải được bằng chính [Chương 2](#) và [Chương 3](#): phần phi tuyến quan trọng nhất của bài toán đã được *gói sẵn* vào các đặc trưng thiết kế (biến tương tác, điểm tổng hợp), nên LR được “san bằng sân chơi”; trong khi cây đơn vẫn chịu nguyên nhược điểm phương sai cao ([kết quả 2.3](#) cho thấy phải trung bình hóa nhiều cây mới khử được). Nói cách khác, bảng kết quả này là minh chứng thực nghiệm cho cả hai luận điểm của đề án: giá trị của thiết kế đặc trưng và giá trị của mô hình tổ hợp.

XGBoost được chọn làm mô hình cuối với căn cứ định lượng rõ ràng: dẫn đầu *đồng thời*

AUC, F_1 , F_2 và Precision; chênh lệch AUC với RF tuy nhỏ (0,0043) nhưng có ý nghĩa thống kê theo kiểm định DeLong trên cùng tập kiểm tra ($z = 4,18$, $p < 0,001$ — chi tiết ở Phụ lục B); và cơ chế `scale_pos_weight` cho phép chỉnh trọng số lớp ngay trong hàm mất mát.

Bảng 4.1: Kết quả bốn mô hình trên tập kiểm tra. Recall/Precision/ F_1 / F_2 tính tại ngưỡng tối ưu F_2 riêng của từng mô hình (chọn trên tập kiểm định).

Mô hình	AUC-ROC	Ngưỡng F_2	Recall	Precision	F_1	F_2
Logistic Regression	0,8630	0,530	68,7%	26,7%	0,384	0,522
Decision Tree (CART)	0,8579	0,630	66,8%	27,8%	0,392	0,521
Random Forest	0,8671	0,480	72,9%	24,5%	0,367	0,523
XGBoost	0,8714	0,625	66,9%	29,9%	0,414	0,536

Hình 4.1 vẽ bốn đường ROC trên cùng hệ trục — mỗi điểm trên một đường ứng với một mức ngưỡng, nên hình cho phép so sánh các mô hình *trên mọi ngưỡng cùng lúc* thay vì tại một ngưỡng cụ thể. Bốn đường bám khá sát nhau (nhất quán với dải AUC hẹp 0,858–0,871), trong đó đường XGBoost (đỏ) nhỉnh hơn rõ nhất ở vùng tỷ lệ dương giả 0,1–0,4 — đúng vùng vận hành thực tế của bài toán (tỷ lệ từ chối vừa phải), còn đường DT (cam) thấp nhất gần như toàn dải.


4.3 Diễn giải SHAP

Áp dụng TreeExplainer cho XGBoost trên mẫu 3.000 hồ sơ của tập kiểm tra. Hai đặc trưng tự thiết kế chiếm vị trí số 1 và số 3 (Bảng 4.2, Hình 4.2), xác nhận hai ý đồ thiết kế ở Mục 3.4: biến tương tác “dùng kiệt hạn mức kèm trễ hạn” và chỉ số trễ hạn có trọng số thực sự mang thông tin mà mô hình khai thác nhiều hơn cả các biến gốc tạo ra chúng.

Bảng 4.2: Năm đặc trưng quan trọng nhất theo |SHAP| trung bình (mẫu 3.000 hồ sơ tập kiểm tra).


Hạng	Đặc trưng	SHAP trung bình
1	<i>FinancialStressIndex</i> (tự thiết kế)	0,577
2	<i>RevolvingUtilizationOfUnsecuredLines</i>	0,535
3	<i>TotalDelinquencyScore</i> (tự thiết kế)	0,410
4	<i>age</i>	0,244
5	<i>NumberOfOpenCreditLinesAndLoans</i>	0,168

Trong Hình 4.2, mỗi cột là giá trị |SHAP| trung bình của một đặc trưng — hiểu là “trung bình mỗi dự báo, đặc trưng này đẩy xác suất vỡ nợ đi bao xa”. Thứ tự cột vì vậy đọc được trực tiếp thành mức độ mô hình *dựa vào* từng đặc trưng. Đáng chú ý nhất: biến tương tác tự thiết kế *FinancialStressIndex* đứng *trên* cả tín hiệu gốc mạnh nhất (tỷ lệ dùng hạn mức), nghĩa



Hình 4.1: Đường ROC của bốn mô hình trên tập kiểm tra.

là tổ hợp “dùng kiệt hạn mức kèm trễ hạn” dự báo tốt hơn từng tín hiệu đứng riêng — đúng giả thuyết nghiệp vụ đặt ra khi thiết kế. Ngược lại, ba biến trễ hạn gốc rơi xuống cuối bảng vì thông tin của chúng đã được hai đặc trưng tổng hợp hấp thụ.



Hình 4.2: Tầm quan trọng đặc trưng theo giá trị SHAP.

4.4 Tối ưu ngưỡng theo F_2

Trước hết cần một giả định chi phí. Đồ án dùng kịch bản minh họa: mỗi hồ sơ vỡ nợ bị bỏ sót (FN) gây tổn thất $c_{FN} = 11.250$ USD — tương ứng khoản vay trung bình 15.000 USD với tỷ lệ mất vốn khi vỡ nợ (LGD) 75%; mỗi hồ sơ tốt bị từ chối nhầm (FP) mất $c_{FP} = 500$ USD lợi nhuận cơ hội. Đây là giả định để minh họa khung quyết định (trong ứng dụng ở [Chương 5](#), hai con số này là tham số người dùng chỉnh được); điểm cốt yếu không phải giá trị tuyệt đối mà là *tỷ lệ bất đối xứng* $c_{FN}/c_{FP} \approx 22$ — bỏ sót đắt hơn từ chối nhầm hàng chục lần, điều ít tranh cãi trong tín dụng.

Theo Nhận xét 2.6, ngưỡng Bayes tương ứng là $t^* = \frac{500}{500+11.250} \approx 0,043$ — nhưng áp ngưỡng này lên điểm số mô hình đồng nghĩa từ chối 97,8% hồ sơ, hiển nhiên bất khả thi về kinh doanh. Có hai nguyên nhân: quy tắc Bayes giả định điểm số là xác suất hiệu chỉnh hoàn hảo (mục sau cho thấy điểm số XGBoost với trọng số lớp bị thổi phồng đáng kể), và nó bỏ qua mọi ràng buộc vận hành. Vì vậy đồ án dùng nó làm mốc tham chiếu và chọn ngưỡng triển khai bằng cách tối ưu trực tiếp F_2 ([công thức \(2.10\)](#)), $\beta = 2$ — ưu tiên Recall gấp đôi, nhất quán với hướng bất


đối xứng chi phí nhưng không cực đoan): quét $t \in [0,05; 0,95]$ trên tập kiểm định cho cực đại tại $t = 0,625$; trên tập kiểm tra ngưỡng này đạt Recall 66,9%, Precision 29,9%, $F_2 = 0,536$ (Bảng 4.3, Hình 4.3).

Bảng 4.3: So sánh các ngưỡng trên tập kiểm tra (22.500 hồ sơ, 1.504 vỡ nợ).

Ngưỡng	Recall	Precision	F_2	Tỷ lệ từ chối	Chi phí (tr.USD)
Mặc định (0,50)	77,5%	22,2%	0,518	23,3%	5,84
F_2-optimal (0,625)	66,9%	29,9%	0,536	14,9%	6,78
F_1 -optimal (0,775)	50,7%	39,5%	0,480	8,6%	8,92
Bayes-optimal (0,043)	99,9%	6,8%	0,268	97,8%	10,26

Hình 4.3 thể hiện quá trình quét ngưỡng trên tập kiểm định: panel trái là F_1/F_2 theo ngưỡng với cực đại F_2 tại 0,625; panel giữa cho thấy cơ chế đánh đổi (Recall giảm, Precision tăng theo ngưỡng); panel phải so sánh bốn ngưỡng chính trên tập kiểm tra.

Cần trung thực rằng *không ngưỡng nào thắng trên mọi tiêu chí* trong Bảng 4.3. Dưới giả định chi phí hai tham số, ngưỡng 0,50 thậm chí có chi phí thấp nhất (5,84 triệu) kèm Recall cao hơn — nhưng phải từ chối 23,3% tổng hồ sơ, gấp rưỡi mức 14,9% của ngưỡng 0,625. Khoản chênh đó là ~ 1.900 khách hàng tốt bị từ chối thêm, mà mô hình chi phí chỉ định giá 500 USD/hồ sơ — con số không phản ánh tổn thất dài hạn về thị phần và trải nghiệm khách hàng khi từ chối gần một phần tư thị trường. Ngưỡng 0,625 được chọn vì là cực đại F_2 (tiêu chí chính, cân Recall–Precision theo đúng khẩu vị rủi ro đã tuyên bố) với tỷ lệ từ chối ở mức vận hành được; so với ngưỡng F_1 (0,775) — lựa chọn “mặc định” nếu không phân biệt chi phí FN/FP — nó tăng Recall từ 50,7% lên 66,9% và giảm khoảng 2,14 triệu USD chi phí ước tính. Ngưỡng Bayes lý thuyết cho Recall gần tuyệt đối nhưng từ chối 97,8% hồ sơ — chỉ có giá trị làm mốc tham chiếu.




Hình 4.3: Tối ưu ngưỡng vận hành theo F_2 .

4.5 Phân tích lỗi và hiệu chỉnh xác suất


Hình 4.4 (panel trái) vẽ phân bố điểm dự báo của hai lớp: lớp tốt dồn về điểm thấp, lớp vỡ nợ trải về phía điểm cao, và phần *giao nhau* của hai phân bố chính là nơi sinh ra FP/FN — các hồ

sơ mang tín hiệu mâu thuẫn (ví dụ thu nhập tốt nhưng đã từng trễ hạn). Panel phải tách riêng nhóm vỡ nợ theo hai phía của ngưỡng 0,625: phần lớn hồ sơ bị bỏ sót (FN) không nằm sát 0 mà rải đều ở vùng điểm trung bình — tức mô hình *có* nhận ra mức rủi ro nhất định nhưng chưa đủ vượt ngưỡng. Hàm ý vận hành: vùng điểm sát dưới ngưỡng nên được chuyển sang thẩm định thủ công — mô hình lo phần dễ chiếm đa số, con người lo phần khó.



Hình 4.4: Trái: phân bố điểm dự báo theo nhãn thật. Phải: nhóm vỡ nợ tách theo bất đúng/bỏ sót tại ngưỡng 0,625.


Về chất lượng xác suất: **Hình 4.5** vẽ biểu đồ độ tin cậy của bốn mô hình — trục hoành là xác suất dự báo, trục tung là tần suất vỡ nợ thực tế trong từng khoảng điểm, đường chéo 45° là hiệu chỉnh hoàn hảo. Cả bốn đường đều nằm *dưới* đường chéo rất xa: các mô hình ước lượng rủi ro cao hơn thực tế một cách hệ thống. Đây là hệ quả đã lường trước của trọng số lớp ≈ 14 (mô hình được huấn luyện như thể lớp vỡ nợ đông gấp 14 lần thật) — và nó giải thích luôn vì sao ngưỡng tối ưu 0,625 nằm cao hơn hẳn 0,5. Điểm Brier định lượng điều này: cả bốn mô hình ở mức 0,119–0,157, *tệ hơn* cả mức nền 0,0624 (luôn dự báo đúng tỷ lệ 6,68%) — điểm số thô xếp hạng tốt nhưng tuyệt đối không đọc được như xác suất.



Hình 4.5: Biểu đồ độ tin cậy và điểm Brier của bốn mô hình (trước hiệu chỉnh).

Khắc phục bằng Platt scaling (**Mục 2.8**): khớp hồi quy logistic một biến trên điểm số của tập kiểm định, áp lên tập kiểm tra. **Hình 4.6** cho thấy kết quả: điểm Brier của XGBoost giảm từ 0,1388 xuống 0,0492 (vượt mức nền 0,0624) và ECE giảm từ 25,0% xuống 0,65% — đường

hiệu chỉnh gần như trùng đường chéo. Vì Platt scaling là phép biến đổi đơn điệu, AUC giữ nguyên 0,8714 và mọi kết luận về ngưỡng/xếp hạng phía trên không đổi; điều thay đổi là con số “xác suất vỡ nợ” hiển thị cho người dùng cuối giờ mang đúng nghĩa đen của nó.




Hình 4.6: XGBoost trước/sau hiệu chỉnh Platt scaling trên tập kiểm tra.

5 Triển khai mô hình thành ứng dụng

Một mô hình chỉ nằm trong notebook thì chưa kiểm chứng được trọn vẹn: các bước tiền xử lý, điền khuyết, dự báo và giải thích phải chạy khớp với nhau trên dữ liệu *mới*, ngoài môi trường thí nghiệm. Vì vậy bước cuối của đề án là đóng gói toàn bộ pipeline thành một ứng dụng web nhỏ — đóng vai trò môi trường triển khai thử nghiệm, mô phỏng cách mô hình sẽ được dùng thật: đưa hồ sơ vào, nhận xác suất, quyết định và lời giải thích ra. Ứng dụng dùng khung Streamlit (thư viện Python dựng giao diện web cho ứng dụng dữ liệu) vì nó cho phép tái sử dụng nguyên vẹn mã tiền xử lý và mô hình đã huấn luyện, phù hợp với phạm vi một bản triển khai minh chứng (không nhằm thay thế hạ tầng chấm điểm sản xuất thật).

5.1 Kiến trúc hệ thống

Ứng dụng có kiến trúc tách lớp như [Hình 5.1](#): lớp giao diện nhận đầu vào, lớp xử lý nạp mô hình đã lưu và bộ tiền xử lý (đúng các đối tượng đã khớp trên tập huấn luyện ở [Chương 3](#) — bảo đảm dữ liệu mới đi qua *cùng một* phép biến đổi), lớp giải thích sinh biểu đồ SHAP. Sơ đồ đọc theo chiều mũi tên: hồ sơ từ giao diện đi qua tiền xử lý vào mô hình, kết quả cùng giải thích SHAP quay về giao diện. Mô hình và TreeExplainer được nạp một lần và lưu đệm để thời gian phản hồi ở mức tương tác.



Hình 5.1: Kiến trúc lớp của ứng dụng Streamlit.

5.2 Hai chế độ vận hành

Ứng dụng mô phỏng hai tình huống sử dụng thực tế của một mô hình chấm điểm:

- **Dự báo đơn lẻ** (tình huống thẩm định một hồ sơ mới): nhập thông tin khách hàng, nhận xác suất vỡ nợ và quyết định Duyệt/Từ chối tại ngưỡng 0,625, kèm biểu đồ SHAP dạng thác nước chỉ rõ đặc trưng nào đẩy rủi ro lên hay kéo xuống — đáp ứng yêu cầu nêu lý do khi từ chối.

- **Đánh giá theo lô** (tình huống hậu kiểm danh mục): tải lên tệp CSV/XLSX, dự báo hàng loạt, cho chỉnh ngưỡng và hai tham số chi phí c_{FN} , c_{FP} (mặc định theo giả định ở Mục 4.4). Nếu tệp có cột nhãn thật SeriousDlqin2yrs, ứng dụng tính AUC, Recall, Precision, F_2 , vẽ ROC/PR, ma trận nhầm lẫn, ước tính tác động chi phí và tóm tắt theo phân khúc thu nhập, nhóm tuổi.

Bản chạy trực tuyến: <https://doandanhlong-loan-prediction.streamlit.app>.

5.3 Chạy thử hậu kiểm theo lô


Để kiểm chứng chế độ hậu kiểm hoạt động đúng từ đầu đến cuối, đồ án tạo tệp batch_demo_from_training_5 (5.000 hồ sơ, 334 vỡ nợ, giữ nguyên tỷ lệ 6,68%) và đưa qua ứng dụng như một người dùng bình thường. Kết quả tại ngưỡng $t = 0,625$ cho trong Bảng 5.1: các chỉ số (AUC 0,8780, Recall 68,26%, $F_2 = 0,5408$) nhất quán với kết quả trên tập kiểm tra ở Chương 4, xác nhận pipeline trong ứng dụng tái lập đúng pipeline thí nghiệm.

Bảng 5.1: Kết quả hậu kiểm theo lô tại ngưỡng $t = 0,625$.

Chỉ số	Giá trị
AUC-ROC	0,8780
Recall	68,26%
Precision	29,53%
F_2 -score	0,5408
TP / FP / FN / TN	228 / 544 / 106 / 4122
Tỷ lệ từ chối	15,44%
Chi phí tại ngưỡng	1.464.500 USD
Chi phí nếu duyệt tất cả	3.757.500 USD
Tiết kiệm mô phỏng	2.293.000 USD

Hình 5.2 trình bày hai kết quả đầu ra chính của lần chạy thử: bên trái là ma trận nhầm lẫn — 228 hồ sơ vỡ nợ bị chặn đúng (TP) đối lấy 544 hồ sơ tốt bị từ chối nhầm (FP), còn sót 106 hồ sơ vỡ nợ (FN); bên phải là quy đổi chi phí — cột “duyet tất cả” (không dùng mô hình, chịu toàn bộ tổn thất vỡ nợ) so với cột “dùng mô hình tại ngưỡng”, chênh lệch 2,293 triệu USD chính là giá trị mô phỏng mà mô hình mang lại trên lô 5.000 hồ sơ này.


Lưu ý về tính trung thực của mô phỏng: lô dữ liệu trên trích từ tập huấn luyện có nhãn, nên con số tuyệt đối lạc quan hơn vận hành thật (nơi nhãn chỉ xuất hiện sau kỳ quan sát 2 năm). Mục đích của bước này là kiểm chứng *chức năng* của pipeline triển khai, không phải đo lại hiệu năng — hiệu năng đã được đo nghiêm ngặt trên tập kiểm tra tách riêng ở Chương 4. Không dùng tập kiểm tra Kaggle để hậu kiểm vì tập này không có nhãn thật.



Hình 5.2: Ma trận nhầm lẫn (trái) và tác động chi phí (phải) trên lần chạy thử theo lô.

5.4 Kiểm chứng ngoài: nộp thử Kaggle

Để có một thước đo hoàn toàn độc lập với mọi lựa chọn nội bộ, đồ án nộp dự đoán trên tập `cs-test.csv` lên hệ thống chấm của cuộc thi Kaggle — hệ thống chấm trên hai phần ẩn của tập kiểm tra: bảng Public (công khai trong cuộc thi) và bảng Private (phần lớn hơn, chỉ công bố khi kết thúc). Kết quả (Hình 5.3): Public AUC = 0,85785 và Private AUC = 0,86482, khá gần AUC nội bộ 0,8714. Khoảng chênh nhỏ và việc Private (tập lớn hơn) cao hơn Public cho thấy mô hình không quá khớp vào dữ liệu huấn luyện — kết quả nội bộ phản ánh đúng năng lực tổng quát hóa.



Hình 5.3: Kết quả nộp thử trên Kaggle.

6 Kết luận và Hướng phát triển

6.1 Kết luận

1. XGBoost đạt $AUC = 0,8714$ trên tập kiểm tra, vượt mục tiêu $0,87$; chênh lệch với Random Forest nhỏ nhưng có ý nghĩa thống kê (DeLong, $p < 0,001$).
2. Thiết kế đặc trưng có chủ đích phát huy tác dụng kép: hai đặc trưng tự thiết kế chiếm vị trí số 1 và số 3 theo SHAP, đồng thời giúp cả mô hình tuyến tính cạnh tranh được với mô hình phi tuyến đơn.
3. Ngưỡng F_2 -optimal ($0,625$) cân bằng Recall ($66,9\%$) với tỷ lệ từ chối vận hành được ($14,9\%$); đánh đổi giữa các ngưỡng được trình bày tường minh thay vì chỉ chọn một con số.
4. Xác suất đầu ra được hiệu chỉnh bằng Platt scaling ($ECE\ 25,0\% \rightarrow 0,65\%$), tách bạch hai vai trò xếp hạng và định lượng rủi ro.
5. SHAP giải thích từng quyết định, đáp ứng yêu cầu minh bạch (Basel III, GDPR).

6.2 Hạn chế

Để các kết quả trên được đọc đúng trọng lượng, cần nêu rõ các giới hạn:

- **Dữ liệu:** bộ *Give Me Some Credit* thu thập tại Mỹ quanh năm 2011 — quan hệ giữa đặc trưng và rủi ro có thể khác với tín dụng Việt Nam hiện nay; mỗi hồ sơ là một ảnh chụp tĩnh, không có lịch sử giao dịch theo thời gian.
- **Đánh giá:** dữ liệu được chia ngẫu nhiên, chưa kiểm chứng theo trục thời gian (huấn luyện quá khứ — kiểm tra tương lai) như môi trường vận hành thật; nhãn nhị phân “trễ hạn 90+ ngày trong 2 năm” không phân biệt mức độ tổn thất giữa các hồ sơ vỡ nợ.
- **Giả định chi phí:** cặp $(c_{FN}, c_{FP}) = (11.250, 500)$ USD là kịch bản minh họa; ngân hàng thật cần thay bằng số liệu danh mục của mình (ứng dụng đã cho phép chỉnh hai tham số này).
- **Phạm vi kỹ thuật:** giá trị SHAP tính trên mẫu 3.000 hồ sơ; các kết luận so sánh mô hình gắn với bộ siêu tham số tìm được bằng tìm kiếm ngẫu nhiên, chưa phải tối ưu toàn cục.

6.3 Hướng phát triển

- **Dữ liệu:** kết hợp dữ liệu tín dụng Việt Nam (CIC, SBV); chấm điểm thời gian thực.
- **Mô hình:** mạng nơ-ron có cơ chế chú ý (attention); mô hình hóa lịch sử giao dịch như chuỗi thời gian (LSTM); mô hình tầng trên kết hợp dự báo của nhiều mô hình con (meta-learner).
- **Giải thích:** giải thích phản thực (counterfactual — “cần thay đổi gì để hồ sơ được duyệt”); tìm hồ sơ tương tự làm minh chứng (prototype).
- **Vận hành:** thử nghiệm A/B so sánh hai ngưỡng trên hai nhóm khách hàng thật; giám sát trôi dữ liệu (data drift — phân phối hồ sơ mới lệch dần khỏi dữ liệu huấn luyện); vòng phản hồi cập nhật mô hình theo nhãn mới.

Tài liệu tham khảo

- [1] Ngân hàng Nhà nước Việt Nam (2024). *Báo cáo tình hình ngân hàng 2023*. <https://www.sbv.gov.vn>.
- [2] Basel Committee on Banking Supervision (2018). *Basel III: Finalising post-crisis reforms*. Bank for International Settlements.
- [3] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD*.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12, 2825–2830.
- [6] Kaggle (2011). *Give Me Some Credit*. <https://www.kaggle.com/c/GiveMeSomeCredit>.
- [7] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [8] DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing areas under two or more correlated ROC curves. *Biometrics*, 44(3), 837–845.
- [9] Platt, J. (1999). Probabilistic outputs for support vector machines. *Advances in Large Margin Classifiers*.
- [10] European Union (2018). *General Data Protection Regulation (EU) 2016/679*.
- [11] Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.
- [12] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- [13] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [14] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.
- [15] Breiman, L., Friedman, J., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth.

- [16] Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- [17] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [18] Shapley, L. S. (1953). A value for n -person games. *Contributions to the Theory of Games*, 2, 307–317.
- [19] Lundberg, S. M., et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67.
- [20] Elkan, C. (2001). The foundations of cost-sensitive learning. *IJCAI*, 973–978.
- [21] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *JAIR*, 16, 321–357.
- [22] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE TKDE*, 21(9), 1263–1284.
- [23] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *ICML*, 625–632.
- [24] van Rijsbergen, C. J. (1979). *Information Retrieval* (2nd ed.). Butterworths.

A Siêu tham số XGBoost


Cấu hình dưới đây đọc trực tiếp từ mô hình đã lưu (`models/best_model.pkl`), là kết quả của `RandomizedSearchCV` mô tả ở [Chương 4](#):

```
{
  'n_estimators': 200,      'max_depth': 4,
  'learning_rate': 0.05,    'subsample': 0.8,
  'colsample_bytree': 0.8,  'scale_pos_weight': 13.96, # = n_neg/n_pos
  'reg_lambda': 1.0,        'reg_alpha': 0.1,
  'min_child_weight': 5,    'gamma': 0.1,
  'objective': 'binary:logistic', 'random_state': 42
}
```

Đáng chú ý là tìm kiếm chọn cây khá nông (`max_depth=4`) kèm chính quy hóa đủ cả ba kênh (λ , α , γ — xem [công thức \(2.6\)](#)): với dữ liệu nhiều và mất cân bằng, nhiều cây nông cộng dồn tổng quát hóa tốt hơn ít cây sâu.

B Hình kỹ thuật bổ sung

Các hình dưới đây hỗ trợ cho lập luận ở phần chính nhưng không thiết yếu với mạch đọc, nên được chuyển vào phụ lục kèm giải thích — phòng trường hợp người đọc muốn kiểm tra sâu hơn từng quyết định.




Hình B.1: Minh họa cơ chế SMOTE sinh mẫu lớp thiểu số.

Về **Hình B.1**: minh họa cách SMOTE tạo mẫu vỡ nợ tổng hợp (điểm mới) bằng nội suy tuyến tính giữa các mẫu vỡ nợ thật lân cận. Hình giúp thấy trực quan hạn chế đã nêu ở [Mục 3.5](#): điểm nội suy nằm trên đoạn thẳng nối hai mẫu thật, trong khi hồ sơ tài chính thật không phân bố “tuyến tính” như vậy — đây là một phần lý do đồ án chọn trọng số lớp thay vì SMOTE.


Về **Hình B.2**: thông tin tương hỗ (mutual information) đo mức phụ thuộc *bất kỳ dạng nào* (kể cả phi tuyến) giữa từng đặc trưng và nhãn vỡ nợ — một thước đo độc lập hoàn toàn với mô hình, tính trước khi huấn luyện. Kết quả nhất quán đáng kể với SHAP ở [Mục 4.3](#): hai vị trí dẫn đầu vẫn là FinancialStressIndex và TotalDelinquencyScore (cột đồ — đặc trưng thiết kế), và DelinquencyTrend cũng vào top-4 — ba trong bốn đặc trưng tự thiết kế được một phương pháp “trung lập” xác nhận giá trị, trước cả khi mô hình nào được huấn luyện.

Về **Hình B.3**: mỗi điểm là một hồ sơ; trục hoành là giá trị đặc trưng, trục tung là đóng góp SHAP của nó. Hình cho thấy *dạng* quan hệ chứ không chỉ độ lớn: ví dụ với tỷ lệ dùng hạn mức, đóng góp vào rủi ro gần như phẳng ở mức thấp rồi tăng dốc khi tiến về 1 (dùng kiệt hạn mức) — bằng chứng trực tiếp về tính phi tuyến mà mô hình tuyến tính không bắt được, củng cố lựa chọn mô hình cây.


Về **Hình B.4**: đường cong học vẽ AUC trên tập huấn luyện và tập kiểm định theo số mẫu huấn luyện. Khi tăng từ 10 nghìn lên 70 nghìn mẫu, AUC huấn luyện giảm từ $\sim 0,96$ về $\sim 0,885$ trong khi AUC kiểm định tăng lên $\sim 0,864$; khoảng cách hai đường thu hẹp từ 0,12 xuống $\sim 0,02$, dưới ngưỡng cảnh báo 0,03 (panel phải). Diễn giải: ở cỡ mẫu nhỏ mô hình quá khớp rõ



Hình B.2: Thông tin tương hỗ giữa đặc trưng và nhãn.



Hình B.3: Đồ thị phụ thuộc SHAP cho đặc trưng chính.



Hình B.4: Đường cong học của XGBoost.

rệt, nhưng với toàn bộ dữ liệu hiện có thì đã vào vùng lành mạnh và hai đường gần bão hòa — thu thập thêm dữ liệu cùng loại sẽ không cải thiện nhiều; muốn tốt hơn cần đặc trưng mới hoặc nguồn dữ liệu mới.

DeLong Test — XGBoost vs Random Forest (same test set)

Model A	Model B	AUC A	AUC B	Δ AUC	z-stat	p-value	Kết luận
XGBoost	RF	0.8714	0.8671	+0.0043	4.1833	0.0000	Sig. ($p<0.05$)

Hình B.5: Kiểm định DeLong cho cặp XGBoost–Random Forest trên tập kiểm tra.

Về **Hình B.5**: kiểm định DeLong so sánh AUC của XGBoost (0,8714) và Random Forest (0,8671) trên *cùng* tập kiểm tra 22.500 hồ sơ (hai mô hình chấm điểm cùng các hồ sơ nên hai AUC tương quan — DeLong xử lý đúng sự tương quan này, điều mà so sánh hai khoảng tin cậy độc lập không làm được). Kết quả $z = 4,18, p < 0,001$: chênh lệch 0,0043 AUC tuy nhỏ về độ lớn nhưng có ý nghĩa thống kê — với 22.500 quan sát, sai số ước lượng AUC đủ nhỏ để phân biệt được hai mô hình. Đây là cơ sở định lượng cho việc chọn XGBoost ở **Chương 4**. (Ghi chú trên hình: nhãn “same test set” và mô hình RF dùng trong kiểm định là đúng các mô hình lưu tại models/.)